

Lab 02 guiado • Manipulación de datos

Elegir, resumir y desconfiar de las cifras globales

- 1 Cada paso se muestra primero aquí. Un clic avanza.
- 2 Abajo aparece lo que Python recuerda, que en Colab no se ve.
- 3 Después lo hacen en Colab, y les tiene que salir igual.

¿Con qué datos vamos a trabajar?

Corre la celda. Lee tres tablas y une la generación con la ficha de cada central, como en el Lab 01.



Paso 1

```
DATOS = "https://raw.githubusercontent.com/RodrigoMSB/curso-python-minergia/main/datos/"
import pandas as pd

centrales = pd.read_csv(DATOS + "centrales.csv")
generacion = pd.read_csv(DATOS + "generacion.csv", parse_dates=["fecha"])
demanda = pd.read_csv(DATOS + "demanda.csv", parse_dates=["fecha"])

# La generación de cada hora con la ficha de su central al lado.
gen = pd.merge(generacion, centrales, on="central", how="left")
print("Generación con ficha", gen.shape)
print("Demanda", demanda.shape)
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

Todavía nada. La memoria está vacía.

¿Con qué datos vamos a trabajar?

Corre la celda. Lee tres tablas y une la generación con la ficha de cada central, como en el Lab 01.



Paso 1

```
DATOS = "https://raw.githubusercontent.com/RodrigoMSB/curso-python-minergia/main/datos/"
import pandas as pd

centrales = pd.read_csv(DATOS + "centrales.csv")
generacion = pd.read_csv(DATOS + "generacion.csv", parse_dates=["fecha"])
demanda = pd.read_csv(DATOS + "demanda.csv", parse_dates=["fecha"])

# La generación de cada hora con la ficha de su central al lado.
gen = pd.merge(generacion, centrales, on="central", how="left")
print("Generación con ficha", gen.shape)
print("Demanda", demanda.shape)
```

```
Generación con ficha (175680, 8)
Demanda              (61488, 4)
```

LO QUE PYTHON RECUERDA

DATOS

"https://raw.githubusercontent.com/RodrigoMSB/curso-python-minergia/main/datos/"

pd

pandas

centrales

tabla 20 × 5

generacion

tabla 175680 × 4

demanda

tabla 61488 × 4

y 1 más

Tres tablas leídas y una unión. *gen* tiene la generación de cada hora con la ficha de su central.

Tu turno, filtra con dos condiciones

Elige una tecnología y una región en las listas y vuelve a correr la celda.



Paso 2

```
tecnologia = "solar" #@param ["hidro", "solar", "eolica", "gas", "carbon",  
"diesel"]  
region = "Antofagasta" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

El signo & se lee como "y". Cada condición va entre paréntesis.

```
elegidas = gen[(gen["tecnologia"] == tecnologia) & (gen["region"] ==  
region)]
```

```
print("Filas encontradas", len(elegidas))  
print(f"✓ Generación de {tecnologia} en {region}",  
round(elegidas["mwh"].sum()), "Mwh")
```

tecnologia

solar ▼

region

Antofagasta ▼

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

gen

tabla 175680 × 8

demanda

tabla 61488 × 4

generacion

tabla 175680 × 4

centrales

tabla 20 × 5

pd

pandas

y 1 más

Tu turno, filtra con dos condiciones

Elige una tecnología y una región en las listas y vuelve a correr la celda.



```
# Paso 2
tecnologia = "solar" #@param ["hidro", "solar", "eolica", "gas", "carbon",
"diesel"]
region = "Antofagasta" #@param ["Antofagasta", "Atacama", "Coquimbo",
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]

# El signo & se lee como "y". Cada condición va entre paréntesis.
elegidas = gen[(gen["tecnologia"] == tecnologia) & (gen["region"] ==
region)]

print("Filas encontradas", len(elegidas))
print(f"✓ Generación de {tecnologia} en {region}",
round(elegidas["mwh"].sum()), "MWh")
```

tecnologia

solar ▼

region

Antofagasta ▼

Filas encontradas 26352
✓ Generación de solar en Antofagasta 479681 MWh

LO QUE PYTHON RECUERDA

gen

tabla 175680 × 8

tecnologia

"solar"

region

"Antofagasta"

elegidas

tabla 26352 × 8

demanda

tabla 61488 × 4

y 4 más

Las dos condiciones se cumplen a la vez en 26.352 filas.

Tu turno, filtra con dos condiciones

Se elige hidro y Biobío y se vuelve a correr la celda.



Paso 2

```
tecnologia = "hidro" #@param ["hidro", "solar", "eolica", "gas", "carbon",  
"diesel"]  
region = "Biobío" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

El signo & se lee como "y". Cada condición va entre paréntesis.

```
elegidas = gen[(gen["tecnologia"] == tecnologia) & (gen["region"] ==  
region)]
```

```
print("Filas encontradas", len(elegidas))  
print(f"✓ Generación de {tecnologia} en {region}",  
round(elegidas["mwh"].sum()), "Mwh")
```

tecnologia

hidro ▼

region

Biobío ▼

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

elegidas

tabla 26352 × 8

region

"Antofagasta"

tecnologia

"solar"

gen

tabla 175680 × 8

demanda

tabla 61488 × 4

y 4 más

Mientras no se corra la celda, Python sigue recordando los valores anteriores.

Tu turno, filtra con dos condiciones

Se elige hidro y Biobío y se vuelve a correr la celda.



```
# Paso 2
tecnologia = "hidro" #@param ["hidro", "solar", "eolica", "gas", "carbon",
"diesel"]
region = "Biobío" #@param ["Antofagasta", "Atacama", "Coquimbo",
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]

# El signo & se lee como "y". Cada condición va entre paréntesis.
elegidas = gen[(gen["tecnologia"] == tecnologia) & (gen["region"] ==
region)]

print("Filas encontradas", len(elegidas))
print(f"✓ Generación de {tecnologia} en {region}",
round(elegidas["mwh"].sum()), "MWh")
```

tecnologia

hidro ▼

region

Biobío ▼

```
Filas encontradas 26352
✓ Generación de hidro en Biobío 4151930 MWh
```

LO QUE PYTHON RECUERDA

gen

tabla 175680 × 8

tecnologia

"hidro"

region

"Biobío"

elegidas

tabla 26352 × 8

demanda

tabla 61488 × 4

y 4 más

La misma pregunta para otra combinación, sin escribir nada.

¿Se consume menos el fin de semana?

Corre la celda.



```
# Paso 3
# Una columna nueva que dice si cada fila cae en sábado o domingo.
# dayofweek numera los días de 0, lunes, a 6, domingo.
demanda["es_finde"] = demanda["fecha"].dt.dayofweek >= 5

promedio = demanda.groupby("es_finde")["mwh"].mean()
print(promedio.round(1))

caida = 100 * (1 - promedio[True] / promedio[False])
print(f"✓ El fin de semana se consume un {caida:.1f} por ciento menos")
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

elegidas

tabla 26352 × 8

region

"Biobío"

tecnologia

"hidro"

gen

tabla 175680 × 8

demanda

tabla 61488 × 4

y 4 más

¿Se consume menos el fin de semana?

Corre la celda.



```
# Paso 3
# Una columna nueva que dice si cada fila cae en sábado o domingo.
# dayofweek numera los días de 0, lunes, a 6, domingo.
demanda["es_finde"] = demanda["fecha"].dt.dayofweek >= 5

promedio = demanda.groupby("es_finde")["mwh"].mean()
print(promedio.round(1))

caida = 100 * (1 - promedio[True] / promedio[False])
print(f"✓ El fin de semana se consume un {caida:.1f} por ciento menos")
```

```
es_finde
False    231.2
True     213.1
Name: mwh, dtype: float64
✓ El fin de semana se consume un 7.8 por ciento menos
```

LO QUE PYTHON RECUERDA

demanda

tabla 61488 × 5

promedio

serie de 2 valores

caida

7.82

elegidas

tabla 26352 × 8

region

"Biobío"

tecnologia

"hidro"

y 5 más

El fin de semana se consume cerca de un 8 por ciento menos.

¿Cuánto generó cada tecnología en el año?

Corre la celda.



```
# Paso 4
# Agrupar es lo mismo que hace una tabla dinámica.
# Junta las filas de cada tecnología y suma su generación.
por_tecnologia = gen.groupby("tecnologia")["mwh"].sum().round()
por_tecnologia.sort_values(ascending=False)
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

caida

7.82

promedio

serie de 2 valores

elegidas

tabla 26352 × 8

region

"Biobío"

tecnologia

"hidro"

gen

tabla 175680 × 8

y 5 más

¿Cuánto generó cada tecnología en el año?

Corre la celda.



```
# Paso 4
# Agrupar es lo mismo que hace una tabla dinámica.
# Junta las filas de cada tecnología y suma su generación.
por_tecnologia = gen.groupby("tecnologia")["mwh"].sum().round()
por_tecnologia.sort_values(ascending=False)
```

```
tecnologia
hidro      6106351.0
gas        5094126.0
carbon     4666823.0
eolica     1565899.0
solar      671677.0
diesel      40710.0
Name: mwh, dtype: float64
```

LO QUE PYTHON RECUERDA

gen

tabla 175680 × 8

por_tecnologia

serie de 6 valores

caida

7.82

promedio

serie de 2 valores

elegidas

tabla 26352 × 8

y 7 más

Hidro genera más que todas, pero la solar queda quinta aunque es segunda en potencia instalada.

Tu turno, resume con varios cálculos

Elige cómo agrupar en la lista y vuelve a correr la celda.



Paso 5

```
agrupar_por = "tecnologia" #@param ["tecnologia", "region"]
```

*# Cada línea es una columna del resumen. A la izquierda el nombre,
a la derecha la columna y el cálculo.*

```
resumen = gen.groupby(agrupar_por).agg(  
    total_mwh=("mwh", "sum"),  
    promedio_hora=("mwh", "mean"),  
    centrales=("central", "nunique"),  
)  
resumen.round(1).sort_values("total_mwh", ascending=False)
```

agrupar_por

tecnologia ▼

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

por_tecnologia
serie de 6 valores

caida
7.82

promedio
serie de 2 valores

elegidas
tabla 26352 × 8

region
"Biobío"

tecnologia
"hidro"

y 6 más

Tu turno, resume con varios cálculos

Elige cómo agrupar en la lista y vuelve a correr la celda.



```
# Paso 5
agrupar_por = "tecnologia" #@param ["tecnologia", "region"]

# Cada línea es una columna del resumen. A la izquierda el nombre,
# a la derecha la columna y el cálculo.
resumen = gen.groupby(agrupar_por).agg(
    total_mwh=("mwh", "sum"),
    promedio_hora=("mwh", "mean"),
    centrales=("central", "nunique"),
)
resumen.round(1).sort_values("total_mwh", ascending=False)
```

agrupar_por

tecnologia ▼

	total_mwh	promedio_hora	centrales
hidro	6106351.4	139.0	5
gas	5094126.1	193.3	3
carbon	4666823.0	265.6	2
eolica	1565899.4	44.6	4
solar	671677.2	15.3	5
diesel	40709.5	4.6	1

LO QUE PYTHON RECUERDA

gen
tabla 175680 × 8

agrupar_por
"tecnologia"

resumen
tabla 6 × 3

por_tecnologia
serie de 6 valores

caida
7.82

y 9 más

Un resumen con el total, el promedio y el conteo de centrales de cada grupo.

Tu turno, resume con varios cálculos

Se elige region en la lista y se vuelve a correr la celda.



Paso 5

```
agrupar_por = "region" #@param ["tecnologia", "region"]
```

*# Cada línea es una columna del resumen. A la izquierda el nombre,
a la derecha la columna y el cálculo.*

```
resumen = gen.groupby(agrupar_por).agg(  
    total_mwh=("mwh", "sum"),  
    promedio_hora=("mwh", "mean"),  
    centrales=("central", "nunique"),  
)  
resumen.round(1).sort_values("total_mwh", ascending=False)
```

agrupar_por

region ▼

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

resumen

tabla 6 × 3

agrupar_por

"tecnologia"

por_tecnologia

serie de 6 valores

caida

7.82

promedio

serie de 2 valores

y 9 más

Mientras no se corra la celda, Python sigue recordando los valores anteriores.

Tu turno, resume con varios cálculos

Se elige region en la lista y se vuelve a correr la celda.

Respuesta de la celda

	total_mwh	promedio_hora	centrales
Biobío	8539297.1	194.4	5
Antofagasta	2447591.2	69.7	4
Valparaíso	2416309.5	137.5	2
Los Lagos	1954421.7	111.2	2
Coquimbo	1332262.6	50.6	3
Metropolitana	1263708.1	71.9	2
Atacama	191996.3	10.9	2

LO QUE PYTHON RECUERDA

gen
tabla 175680 × 8

agrupar_por
"region"

resumen
tabla 7 × 3

por_tecnologia
serie de 6 valores

caida
7.82

y 9 más

El mismo resumen por región. Biobío tiene 5 centrales y la mayor generación.

¿Cuánto generó cada región con cada tecnología?

Corre la celda. Las regiones quedan en las filas y las tecnologías en las columnas.



```
# Paso 6
# pivot_table arma una tabla de doble entrada, como una tabla dinámica.
# fill_value=0 pone cero donde una región no tiene esa tecnología.
cruce = gen.pivot_table(index="region", columns="tecnologia",
                        values="mwh", aggfunc="sum", fill_value=0)
cruce.round()
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

resumen

tabla 7 × 3

agrupar_por

"region"

por_tecnologia

serie de 6 valores

caida

7.82

promedio

serie de 2 valores

y 9 más

¿Cuánto generó cada región con cada tecnología?

Corre la celda. Las regiones quedan en las filas y las tecnologías en las columnas.



```
# Paso 6
# pivot_table arma una tabla de doble entrada, como una tabla dinámica.
# fill_value=0 pone cero donde una región no tiene esa tecnología.
cruce = gen.pivot_table(index="region", columns="tecnologia",
                        values="mwh", aggfunc="sum", fill_value=0)

cruce.round()
```

	carbon	diesel	eolica	gas	hidro	solar
Antofagasta	1967910.0	0.0	0.0	0.0	0.0	479681.0
Atacama	0.0	0.0	0.0	0.0	0.0	191996.0
Biobío	2698913.0	0.0	0.0	1688455.0	4151930.0	0.0
Coquimbo	0.0	0.0	1332263.0	0.0	0.0	0.0
Los Lagos	0.0	0.0	0.0	0.0	1954422.0	0.0
Metropolitana	0.0	40710.0	0.0	1222999.0	0.0	0.0
Valparaíso	0.0	0.0	233637.0	2182673.0	0.0	0.0

LO QUE PYTHON RECUERDA

gen
tabla 175680 × 8

cruce
tabla 7 × 6

resumen
tabla 7 × 3

agrupar_por
"region"

por_tecnologia
serie de 6 valores

caida
7.82

y 9 más

Una tabla de doble entrada. Los ceros son combinaciones que no existen.

¿Qué tan seguido genera cada tecnología?

Corre la celda. El factor de planta es lo que generó una central dividido por lo máximo que podía generar.



```
# Paso 7
# Una columna nueva calculada para las 175.680 filas de una vez.
gen["factor_planta"] = gen["mwh"] / gen["potencia_mw"]

factor = gen.groupby("tecnologia")["factor_planta"].mean().round(3)
factor.sort_values(ascending=False)
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

cruce

tabla 7 × 6

resumen

tabla 7 × 3

agrupar_por
"region"

por_tecnologia

serie de 6 valores

caida

7.82

promedio

serie de 2 valores

y 9 más

¿Qué tan seguido genera cada tecnología?

Corre la celda. El factor de planta es lo que generó una central dividido por lo máximo que podía generar.



```
# Paso 7
# Una columna nueva calculada para las 175.680 filas de una vez.
gen["factor_planta"] = gen["mwh"] / gen["potencia_mw"]

factor = gen.groupby("tecnologia")["factor_planta"].mean().round(3)
factor.sort_values(ascending=False)
```

```
tecnologia
gas      0.663
carbon   0.640
hidro    0.549
eolica   0.315
diesel   0.103
solar    0.080
Name: factor_planta, dtype: float64
```

LO QUE PYTHON RECUERDA

gen

tabla 175680 × 9

factor

serie de 6 valores

cruce

tabla 7 × 6

resumen

tabla 7 × 3

agrupar_por

"region"

y 11 más

En estos datos inventados la solar tiene el factor más bajo, porque de noche no genera.

¿Sube el precio cuando sube la demanda?

Corre la celda. Une los precios de enero con la demanda de enero.



Paso 8

```
import requests
respuesta = requests.get(DATOS + "precios_nudo.json").json()
precios = pd.json_normalize(respuesta["datos"])
precios["fecha"] = pd.to_datetime(precios["fecha"])

# Se unen por fecha, hora y región a la vez.
mix = pd.merge(precios, demanda, on=["fecha", "hora", "region"], how="inner")
print("Filas unidas", len(mix))

# La correlación va de -1 a 1. Cerca de 1 es que suben juntos.
print("✓ Correlación con todas las regiones", round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

factor

serie de 6 valores

cruce

tabla 7 × 6

resumen

tabla 7 × 3

agrupar_por

"region"

por_tecnologia

serie de 6 valores

caida

7.82

y 10 más

¿Sube el precio cuando sube la demanda?

Corre la celda. Une los precios de enero con la demanda de enero.



Paso 8

```
import requests
respuesta = requests.get(DATOS + "precios_nudo.json").json()
precios = pd.json_normalize(respuesta["datos"])
precios["fecha"] = pd.to_datetime(precios["fecha"])

# Se unen por fecha, hora y región a la vez.
mix = pd.merge(precios, demanda, on=["fecha", "hora", "region"], how="inner")
print("Filas unidas", len(mix))

# La correlación va de -1 a 1. Cerca de 1 es que suben juntos.
print("✓ Correlación con todas las regiones", round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

Filas unidas 5208
✓ Correlación con todas las regiones 0.979

LO QUE PYTHON RECUERDA

DATOS

"https://raw.githubusercontent.com..."

pd

pandas

demanda

tabla 61488 × 5

respuesta

datos con 2 partes

precios

tabla 5208 × 4

y 14 más

0,979 parece decir que precio y demanda suben juntos casi siempre.

¿Y dentro de cada región?

Elige una región en la lista y vuelve a correr la celda. Compara con el número del paso anterior.



Paso 9

```
region = "Metropolitana" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

region

Metropolitana ▼

```
una = mix[mix["region"] == region]  
correlacion = round(una["precio_usd_mwh"].corr(una["mwh"]), 3)  
print(f"Correlación dentro de {region}", correlacion)  
print("Correlación con todas las regiones",  
round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

mix

tabla 5208 × 6

precios

tabla 5208 × 4

respuesta

datos con 2 partes

factor

serie de 6 valores

cruce

tabla 7 × 6

y 14 más

¿Y dentro de cada región?

Elige una región en la lista y vuelve a correr la celda. Compara con el número del paso anterior.



Paso 9

```
region = "Metropolitana" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

region

Metropolitana ▼

```
una = mix[mix["region"] == region]  
correlacion = round(una["precio_usd_mwh"].corr(una["mwh"]), 3)  
print(f"Correlación dentro de {region}", correlacion)  
print("Correlación con todas las regiones",  
round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

```
Correlación dentro de Metropolitana 0.917  
Correlación con todas las regiones 0.979
```

LO QUE PYTHON RECUERDA

region

"Metropolitana"

mix

tabla 5208 × 6

una

tabla 744 × 6

correlacion

0.92

precios

tabla 5208 × 4

y 16 más

Dentro de la Metropolitana la correlación es 0,917.

¿Y dentro de cada región?

Se elige Atacama en la lista y se vuelve a correr la celda.



Paso 9

```
region = "Atacama" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

```
una = mix[mix["region"] == region]  
correlacion = round(una["precio_usd_mwh"].corr(una["mwh"]), 3)  
print(f"Correlación dentro de {region}", correlacion)  
print("Correlación con todas las regiones",  
round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

region

Atacama ▼

Clic en el botón de play para correr la celda

LO QUE PYTHON RECUERDA

correlacion

0.92

una

tabla 744 × 6

mix

tabla 5208 × 6

precios

tabla 5208 × 4

respuesta

datos con 2 partes

y 16 más

Mientras no se corra la celda, Python sigue recordando los valores anteriores.

¿Y dentro de cada región?

Se elige Atacama en la lista y se vuelve a correr la celda.



Paso 9

```
region = "Atacama" #@param ["Antofagasta", "Atacama", "Coquimbo",  
"Valparaíso", "Metropolitana", "Biobío", "Los Lagos"]
```

region

Atacama ▼

```
una = mix[mix["region"] == region]  
correlacion = round(una["precio_usd_mwh"].corr(una["mwh"]), 3)  
print(f"Correlación dentro de {region}", correlacion)  
print("Correlación con todas las regiones",  
round(mix["precio_usd_mwh"].corr(mix["mwh"]), 3))
```

Correlación dentro de Atacama 0.125
Correlación con todas las regiones 0.979

Un total puede engañar. Con todas las regiones juntas da 0,979. Región por región va de 0,125 a 0,917. Antes de informar una cifra global, se mira por grupo.

LO QUE PYTHON RECUERDA

region
"Atacama"

mix
tabla 5208 × 6

una
tabla 744 × 6

correlacion
0.12

precios
tabla 5208 × 4

respuesta
datos con 2 partes

y 15 más

Dentro de Atacama es 0,125. Casi no hay relación.

Ahora en Colab

Ahora abran el Lab 02 guiado y hagan los nueve pasos. Les tiene que salir lo mismo que acabamos de ver.

Si algo no calza, escriban en el chat el número del paso.