Guía del alumno

Módulo 4, Minería de datos

Ruta guiada

Análisis Avanzado de Datos con Python

Cómo usar esta guía

Esta guía acompaña al Lab 04 guiado y sigue sus dos partes en el mismo orden y con los mismos nombres del cuaderno. La Parte 1, En clase, tiene cinco pasos, de Paso 1 de 5 a Paso 5 de 5, y se hace en clase. La Parte 2, Para estudiar, tiene cuatro estudios, de Estudio 1 de 4 a Estudio 4 de 4, y se hace después de clase con esta guía, una vez corrida la Parte 1. Cada paso trae el código y la respuesta tal como aparecen en Colab, y una explicación en palabras simples.

En los pasos no hay que escribir código. Lo que cambia se cambia en las listas desplegables y en el deslizador, y después se vuelve a correr la celda. El lab responde tres preguntas. Cómo se convierte una bitácora de eventos en canastas que se pueden comparar, cómo se mide si dos eventos aparecen juntos más de lo normal, y qué evento suele venir después de otro, y en cuántos días.

Lo que vas a poder hacer al terminar

- Resumir una bitácora de eventos por tipo, contando y midiendo duración.
- Agrupar los eventos en canastas, como boletas de supermercado.
- Calcular qué tan común es cada evento en las canastas.
- Medir una regla con la confianza y el lift, y saber cuándo no dice nada.
- Encontrar qué evento suele venir después de otro, y en cuántos días.

Todas las respuestas de esta guía vienen de una corrida del cuaderno con los valores que trae por defecto. Los datos del curso son sintéticos, y los patrones de la bitácora se plantaron a propósito al crearlos para poder medirlos.

Parte 1 · En clase

Cinco pasos, uno detrás del otro, que se hacen en clase en el mismo orden del cuaderno.

Paso 1 de 5 · ¿Qué hay en la bitácora?

Este lab trabaja con la bitácora de mantenimiento de 2024. Cada fila es un evento, como lo anota el turno, con la central, la fecha, el tipo de evento y cuántas horas duró.

Paso 1 de 5

```
# Paso 1
DATOS = "https://raw.githubusercontent.com/RodrigoMSB/curso-python-minergia/main/datos/"
import pandas as pd

# La bitácora del año, un evento por fila, como la llena el turno.
mant = pd.read_csv(DATOS + "mantenimiento.csv", parse_dates=["fecha"])

print("Eventos del año", len(mant))
print("Centrales con eventos", mant["central"].nunique())
mant.head()
```

```
Eventos del año 600
Centrales con eventos 20
                      central      fecha     tipo_evento  duracion_horas  \
0         Eólica Campo Abierto 2024-01-01      preventivo               5
1  Parque Solar Quebrada Honda 2024-01-01      preventivo               8
2      Parque Solar Llano Seco 2024-01-02  falla_mecanica              49
3  Parque Solar Quebrada Honda 2024-01-02      inspeccion               6
4          Central Tres Saltos 2024-01-03      correctivo              38

                                    observacion
0  Se registra la lubricación periódica sobre el ...
1  El operador reporta la lubricación periódica, ...
2  El operador reporta vibración fuera de norma, ...
3  Se registra la lectura de instrumentos sobre l...
4  Evento por la reparación de la falla del turno...
```

La bitácora tiene 600 eventos repartidos entre las 20 centrales del curso. Cada evento trae la central, la fecha, el tipo de evento, cuántas horas duró y una observación, el texto libre que escribe el turno. pandas corta los textos largos con tres puntos. La observación se usa en el Módulo 5.

En este lab no se suman megawatts. Se buscan patrones en los eventos, qué pasa junto y qué viene después de qué. Eso es la minería de datos.

La tabla es más ancha que la hoja, así que en esta guía las últimas columnas aparecen más abajo. En Colab se ve completa.

Paso 2 de 5 · ¿Qué le pasó a cada central en cada mes?

En un supermercado, cada boleta junta lo que compró una persona en una visita. Para buscar qué se compra junto, se comparan boletas. Con la bitácora se hace lo mismo.

Paso 2 de 5

```
# Paso 2
# Una columna nueva con el mes de cada evento, del 1 al 12.
mant["mes"] = mant["fecha"].dt.month

# La misma tabla dinámica del Lab 02, ahora contando eventos.
# Una fila por central y mes, y una columna por tipo de evento.
# aggfunc="size" cuenta cuántos eventos cayeron en cada casilla.
conteo = mant.pivot_table(index=["central", "mes"], columns="tipo_evento",
                          aggfunc="size", fill_value=0)
print("Canastas", len(conteo))
conteo.head(6)
```

```
Canastas 215
tipo_evento                    correctivo  evento_climatico  falla_electrica  \
central                   mes
Carboeléctrica Costa Brava 1            0                 0                0
                           2            0                 0                1
                           3            1                 0                0
                           4            0                 0                0
                           5            1                 1                0
                           6            1                 0                0

tipo_evento                    falla_mecanica  inspeccion  preventivo
central                   mes
Carboeléctrica Costa Brava 1                0           0           1
                           2                0           0           1
                           3                0           1           0
                           4                0           0           1
                           5                0           0           0
                           6                1           0           0
```

La celda agrega a la bitácora la columna `mes`, con el mes de cada evento. Después arma una tabla dinámica, la misma del Lab 02, ahora contando eventos. Cada fila es una **canasta**, todo lo que le pasó a una central en un mes. Cada columna es un tipo de evento y cada casilla cuenta cuántas veces pasó. Quedan 215 canastas.

El nombre de la central aparece solo en la primera de sus filas, pandas no lo repite mientras no cambia. En enero la Carboeléctrica Costa Brava tuvo solo un preventivo. En febrero tuvo una falla eléctrica y un preventivo.

Elegir qué es una canasta es una decisión. Con canastas más grandes, por ejemplo un trimestre, casi todo aparece con todo.

La tabla es más ancha que la hoja, así que en esta guía las últimas columnas aparecen más abajo. En Colab se ve completa.

Paso 3 de 5 · ¿En cuántas canastas aparece cada evento?

Para comparar canastas conviene una tabla de sí o no. Una fila por canasta, una columna por tipo de evento, y en cada casilla si ese evento ocurrió o no.

Paso 3 de 5

```
# Paso 3
# Más de cero veces es sí. La tabla queda con True y False.
tabla = conteo > 0

# El promedio de una columna de True y False es la proporción de True.
# Por 100 queda en porcentaje.
print("Porcentaje de canastas donde aparece cada evento")
print((100 * tabla.mean()).round(1).sort_values(ascending=False))
tabla.head(6)
```

```
Porcentaje de canastas donde aparece cada evento
tipo_evento
preventivo          56.3
correctivo          40.0
inspeccion          39.5
falla_mecanica      36.3
evento_climatico    25.6
falla_electrica     19.5
dtype: float64
tipo_evento                    correctivo  evento_climatico  falla_electrica  \
central                    mes
Carboeléctrica Costa Brava 1         False             False            False
                           2         False             False             True
                           3          True             False            False
                           4         False             False            False
                           5          True              True            False
                           6          True             False            False

tipo_evento                    falla_mecanica  inspeccion  preventivo
central                    mes
Carboeléctrica Costa Brava 1             False       False        True
                           2             False       False        True
                           3             False        True       False
                           4             False       False        True
                           5             False       False       False
                           6              True       False       False
```

`conteo > 0` le hace la misma pregunta a cada casilla, si el evento pasó más de cero veces. La respuesta es `True` o `False`, y `tabla` queda de sí o no. Desde aquí importa si el evento pasó en la canasta, no cuántas veces.

Para Python, `True` vale 1 y `False` vale 0. Por eso el promedio de una columna de `True` y `False` es la proporción de `True`, y por 100 queda en porcentaje. El preventivo aparece en el 56.3 por ciento de las canastas, el correctivo en el 40.0 y la falla eléctrica en el 19.5. Ese porcentaje es lo normal de cada evento, y es el punto de comparación del paso siguiente.

La última línea de la lista, la que dice `dtype`, la agrega Python para describir el resultado y se puede ignorar.

La tabla es más ancha que la hoja, así que en esta guía las últimas columnas aparecen más abajo. En Colab se ve completa.

Paso 4 de 5 · Tu turno, si pasa una cosa, ¿pasa la otra?

Una regla dice si pasa esto, entonces pasa esto otro. Se mide con dos números, la confianza y el lift.

Paso 4 de 5

```
# Paso 4
si = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]
entonces = "correctivo" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# Solo las canastas donde pasó si, con un filtro como los del Lab 02.
con_si = tabla[tabla[si] == True]
print(f"Canastas con {si}", len(con_si))

# Confianza, de esas canastas, en qué porcentaje pasó también entonces.
confianza = 100 * con_si[entonces].mean()
# Lo normal, en qué porcentaje de todas las canastas pasa entonces.
normal = 100 * tabla[entonces].mean()
# Lift, cuántas veces más de lo normal. Sobre 1 van juntos, cerca de 1 no hay relación.
lift = confianza / normal

print("Confianza", round(confianza, 1), "por ciento")
print(f"{entonces} en todas las canastas", round(normal, 1), "por ciento")
print("Lift", round(lift, 2))
```

```
Canastas con falla_electrica 42
Confianza 83.3 por ciento
correctivo en todas las canastas 40.0 por ciento
Lift 2.08
```

La celda se queda con las canastas donde pasó el evento de la lista `si`, con un filtro como los del Lab 02. Hay 42 canastas con falla eléctrica.

La **confianza** dice en qué porcentaje de esas canastas pasó también el evento de la lista `entonces`. Es el promedio de la columna `correctivo` solo en esas 42 canastas, y da 83.3 por ciento.

El **lift** compara esa confianza con lo normal. El correctivo aparece en el 40.0 por ciento de todas las canastas. Con falla eléctrica aparece en el 83.3, o sea 2.08 veces más de lo normal. Un lift sobre 1 quiere decir que van juntos. Cerca de 1, que no hay relación.

Prueba falla_electrica con preventivo. La confianza es 52.4 por ciento, que parece mucho, pero el lift es 0.93. El preventivo aparece en más de la mitad de las canastas, haya o no falla eléctrica. Si eliges el mismo evento en las dos listas, la confianza da 100 por ciento, porque un evento siempre está en las canastas donde está él mismo.

Paso 5 de 5 · Tu turno, ¿en cuántos días llega el correctivo?

Saber que después de una falla eléctrica viene un correctivo no basta para programar cuadrillas. Hay que saber en cuántos días.

Paso 5 de 5

```
# Paso 5
dias = 3 #@param {type:"slider", min:0, max:7, step:1}

# La planilla que arma el área de mantenimiento. Una fila por falla eléctrica,
# con los días que pasaron hasta el primer correctivo en la misma central.
# Si nunca llegó un correctivo, la casilla viene vacía.
fallas = pd.read_csv(DATOS + "fallas_electricas.csv")

# Las fallas cuyo correctivo llegó dentro de la ventana.
a_tiempo = fallas[fallas["dias_hasta_correctivo"] <= dias]
porcentaje = 100 * len(a_tiempo) / len(fallas)

print("Fallas eléctricas", len(fallas))
print(f"Con un correctivo dentro de {dias} días", len(a_tiempo))
print("Porcentaje", round(porcentaje, 1))
print("Lo que se plantó al crear los datos, 70 por ciento")
```

```
Fallas eléctricas 47
Con un correctivo dentro de 3 días 34
Porcentaje 72.3
Lo que se plantó al crear los datos, 70 por ciento
```

La celda lee `fallas_electricas.csv`, una planilla con una fila por cada falla eléctrica del año. La columna `dias_hasta_correctivo` dice cuántos días pasaron hasta el primer correctivo en la misma central. Si nunca llegó uno, la casilla viene vacía.

Después filtra las fallas cuyo correctivo llegó dentro de los días del deslizador. Con 3 días, 34 de las 47 fallas eléctricas tienen un correctivo, el 72.3 por ciento. Al crear los datos del curso se plantó un 70 por ciento, así que la medición está cerca.

Mueve el deslizador. Con 0 días, el mismo día, son 7 fallas y el 14.9 por ciento. Con 1 día son 19 y el 40.4. Con 7 días son otra vez 34 y el 72.3, no sube más.

> **LA VENTANA LA DECIDE QUIEN ANALIZA**
>
> Con 0 días da 14,9 por ciento y con 3 días da 72,3. Desde los 3 días ya no sube más, porque así se crearon los datos. En un informe se escribe la ventana que se usó, porque cambia el resultado. Estos datos son inventados y el patrón se plantó a propósito para poder medirlo.

Parte 2 · Para estudiar

Estos pasos se hacen después de clase, con esta guía. Antes de empezar hay que correr toda la Parte 1 del cuaderno, porque los estudios usan sus tablas.

Estudio 1 de 4 · ¿Cuánto dura cada tipo de evento?

Antes de buscar patrones conviene conocer los seis tipos de evento.

Estudio 1 de 4

```
# Estudio 1
resumen = mant.groupby("tipo_evento")["duracion_horas"].agg(
    eventos="count",
    horas_promedio="mean",
    horas_maximo="max",
)
resumen.round(1).sort_values("eventos", ascending=False)
```

```
                eventos  horas_promedio  horas_maximo
tipo_evento
preventivo          158            14.5            24
correctivo          118            38.9            72
inspeccion           99             4.7             8
falla_mecanica       98            50.6            94
evento_climatico     80            21.2            36
falla_electrica      47            22.4            48
```

El preventivo es el más frecuente, con 158 eventos, y es corto, 14.5 horas en promedio. La falla mecánica tiene 98 eventos pero es la que deja más tiempo detenida una central, 50.6 horas en promedio y hasta 94. La inspección es la más corta, menos de 5 horas.

La tabla usa `agg` con tres cálculos a la vez, igual que en el Lab 02. Contar y medir la duración por separado da dos lecturas distintas. Lo más frecuente no es lo que más cuesta.

Estudio 2 de 4 · Tu turno, mira qué le pasa a cada tecnología

Un tipo de evento puede concentrarse en algunas centrales. Para saberlo hay que pegarle a cada evento la ficha de su central.

Estudio 2 de 4

```
# Estudio 2
tipo = "evento_climatico" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# A cada evento se le pega la ficha de su central, como en el Lab 01.
centrales = pd.read_csv(DATOS + "centrales.csv")
con_ficha = pd.merge(mant, centrales, on="central", how="left")

elegidos = con_ficha[con_ficha["tipo_evento"] == tipo]
print(f"✓ Hay {len(elegidos)} eventos de tipo {tipo}")
elegidos["tecnologia"].value_counts()
```

```
✓ Hay 80 eventos de tipo evento_climatico
tecnologia
eolica    55
hidro     12
solar      6
gas        4
carbon     2
diesel     1
Name: count, dtype: int64
```

La celda une la bitácora con la tabla de centrales, como en el Lab 01, y se queda con los eventos del tipo elegido. Hay 80 eventos climáticos, y 55 son de centrales eólicas. Tiene sentido, el viento fuerte es lo que más afecta a un parque eólico.

Elige falla_electrica en la lista y vuelve a correr la celda para ver cómo se reparte otro tipo.

Estudio 3 de 4 · Tu turno, ¿qué eventos acompañan a cada uno?

Probar las parejas de a una es lento. La celda hace el cálculo del Paso 4 con un evento y todos los demás a la vez.

Estudio 3 de 4

```
# Estudio 3
si = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# Lo mismo del Paso 4, para todos los entonces a la vez.
# mean saca la proporción de cada columna, en las canastas con si y en todas.
con_si = tabla[tabla[si] == True]
lift = con_si.mean() / tabla.mean()

# drop quita el mismo evento, porque siempre se acompaña a sí mismo.
lift.drop(si).round(2).sort_values(ascending=False)
```

```
tipo_evento
correctivo          2.08
preventivo          0.93
falla_mecanica      0.92
inspeccion          0.90
evento_climatico    0.65
dtype: float64
```

La celda filtra las canastas donde pasó el evento de la lista, igual que el Paso 4. Después saca el promedio de todas las columnas a la vez, en esas canastas y en todas, y divide uno por el otro. Lo que queda es el lift de ese evento con cada uno de los demás. `drop` quita al mismo evento, que siempre se acompaña a sí mismo.

Con falla_electrica, el correctivo tiene lift 2.08 y todos los demás quedan bajo 1. Elige evento_climatico y vuelve a correr la celda. La falla mecánica tiene lift 1.90, casi el doble de lo normal. Con preventivo ningún evento llega a 1.

La última línea, la que dice `dtype`, la agrega Python para describir el resultado y se puede ignorar.

> **UNA CONFIANZA ALTA NO BASTA**
>
> Falla eléctrica con preventivo tiene un 52,4 por ciento de confianza y parece una regla. Pero el preventivo aparece en el 56,3 por ciento de todas las canastas. Su lift es 0,93, o sea que no aparece más de lo normal. Las dos reglas que sí dicen algo tienen lift cercano a 2. Que dos eventos vayan juntos no prueba que uno cause el otro.

Estudio 4 de 4 · Tu turno, ¿qué viene después de cada evento?

Las canastas no saben de orden. Dentro de un mes da lo mismo qué pasó primero. Este paso mira el orden en el tiempo.

Estudio 4 de 4

```
# Estudio 4
evento = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# Se ordena por central y fecha, y shift(-1) trae el evento de la fila siguiente.
# groupby("central") cuida que el siguiente sea de la misma central.
ordenados = mant.sort_values(["central", "fecha"]).copy()
ordenados["siguiente"] = ordenados.groupby("central")["tipo_evento"].shift(-1)

# Las filas del evento elegido, y en qué porcentaje viene cada siguiente.
# normalize=True entrega proporciones en vez de conteos.
despues = ordenados[ordenados["tipo_evento"] == evento]
print(f"Después de {evento}, el evento siguiente en la misma central, en porcentaje")
(100 * despues["siguiente"].value_counts(normalize=True)).round(1)
```

```
Después de falla_electrica, el evento siguiente en la misma central, en porcentaje
siguiente
correctivo         78.7
preventivo         10.6
falla_electrica     6.4
inspeccion          4.3
Name: proportion, dtype: float64
```

La celda ordena la bitácora por central y fecha, y `shift(-1)` trae a cada fila el evento siguiente de la misma central. Después se queda con las filas del evento elegido y cuenta qué vino después. `normalize=True` deja la cuenta en proporciones, y por 100 en porcentaje.

Después de una falla eléctrica, el evento siguiente en la misma central es un correctivo en el 78.7 por ciento de los casos. Elige evento_climatico y vuelve a correr la celda. Lo que viene después es una falla mecánica en el 60.3 por ciento. Con preventivo no hay un siguiente que destaque, ninguno llega al 30 por ciento.

La última línea, la que dice `Name` y `dtype`, la agrega Python para describir el resultado y se puede ignorar.

Para seguir practicando

Al final del cuaderno hay cuatro ejercicios para quien quiera seguir después de clase. En ellos sí se escribe código. Antes de empezar hay que correr todo el cuaderno con Entorno de ejecución, Ejecutar todo, porque los ejercicios usan las tablas de los pasos.

Cada ejercicio tiene una celda vacía para escribir la respuesta y una solución plegada, que conviene abrir solo después de intentarlo. Las soluciones no están en esta guía.

- **Ejercicio 1.** Armar las canastas por trimestre en vez de por mes y ver qué pasa con los porcentajes.
- **Ejercicio 2.** Armar una tabla con todas las parejas de eventos y buscar cuáles anuncian un correctivo.
- **Ejercicio 3.** Medir el segundo patrón plantado, el clima y las fallas mecánicas el mismo día.
- **Ejercicio 4.** Buscar qué central se parece a cuál por la forma de su día.

Para repasar

Referencia rápida

Lo que se escribe	Para qué sirve
`groupby(...).agg(...)`	Varios cálculos por grupo
`value_counts()`	Cuántas veces aparece cada valor
`dt.month` · `dt.quarter`	El mes o el trimestre de una fecha
`pivot_table(..., aggfunc="size")`	Cuenta los eventos de cada casilla
`conteo > 0`	Convierte los conteos en True o False
`mean()` de una columna de `True` y `False`	La proporción de True
`tabla[tabla[si] == True]`	Las canastas donde pasó un evento
`shift(-1)`	Trae el valor de la fila siguiente
`value_counts(normalize=True)`	Cada valor como proporción del total

Si algo sale mal

Lo que aparece en pantalla	Qué pasó
`NameError: name 'mant' is not defined`	Corriste un paso sin correr antes el Paso 1, que es el que lee la bitácora.
`NameError: name 'tabla' is not defined`	El Paso 4 y el Estudio 3 usan la tabla de sí o no que arma el Paso 3. Corre el Paso 3 antes.
La confianza da 100 por ciento	En el Paso 4 elegiste el mismo evento en las dos listas. Un evento siempre está en las canastas donde está él mismo.
La respuesta no cambió después de cambiar la lista o el deslizador	Cambiar un campo no corre la celda. Hay que volver a apretar el botón de play.

Tres preguntas de repaso

1. Qué es una canasta en este lab

Todo lo que le pasó a una central en un mes, como una boleta con las compras de una visita al supermercado.

2. Por qué una confianza de 52,4 por ciento puede no decir nada

Porque el segundo evento ya aparece en más de la mitad de las canastas. El lift cercano a 1 dice que no aparece más de lo normal.

3. Por qué hay que escribir la ventana de días en un informe

Porque el resultado cambia con la ventana. Con 0 días da 14,9 por ciento y con 3 días da 72,3.

El Lab 04 guiado en una plana

Para imprimir y tener al lado durante el curso

Los pasos de las dos partes

N.	La pregunta	La idea
Parte 1, en clase		
1	¿Qué hay en la bitácora?	Un evento por fila
2	¿Qué le pasó a cada central en cada mes?	Canastas con una tabla dinámica
3	¿En cuántas canastas aparece cada evento?	Tabla de sí o no
4	Tu turno, si pasa una cosa, ¿pasa la otra?	Confianza y lift
5	Tu turno, ¿en cuántos días llega el correctivo?	La ventana de días
Parte 2, para estudiar		
1	¿Cuánto dura cada tipo de evento?	Contar y medir duración
2	Tu turno, mira qué le pasa a cada tecnología	Pegar la ficha y contar
3	Tu turno, ¿qué eventos acompañan a cada uno?	El lift con todos a la vez
4	Tu turno, ¿qué viene después de cada evento?	El orden en el tiempo

Cómo se lee una regla

Confianza	De las canastas con el primero, cuántas tienen el segundo
Lo normal	En cuántas canastas aparece el segundo, en general
Lift	Confianza dividida por lo normal
Lift sobre 1	Van juntos más de lo normal
Lift cerca de 1	No hay relación, aunque la confianza sea alta
Ir juntos	No prueba que uno cause el otro

Las distancias entre perfiles, los algoritmos apriori y FP-Growth y las reglas con más de un evento están en la ruta completa de este módulo.