

Guía del alumno

Módulo 4, Minería de datos

Ruta guiada

Análisis Avanzado de Datos con Python

Cómo usar esta guía

Esta guía acompaña al Lab 04 guiado. Sigue sus nueve pasos en el mismo orden y con el mismo nombre, Paso 1 de 9 hasta Paso 9 de 9. Cada paso trae el código y la respuesta tal como aparecen en Colab, y una explicación en palabras simples.

En los pasos no hay que escribir código. Lo que cambia se cambia en las listas desplegadas y en el deslizador, y después se vuelve a correr la celda. El lab responde tres preguntas. Cómo se convierte una bitácora de eventos en canastas que se pueden comparar, cómo se mide si dos eventos aparecen juntos más de lo normal, y qué evento suele venir después de otro, y en cuántos días.

Lo que vas a poder hacer al terminar

- Resumir una bitácora de eventos por tipo, contando y midiendo duración.
- Agrupar los eventos en canastas, como boletas de supermercado.
- Calcular qué tan común es cada evento en las canastas.
- Medir una regla con la confianza y el lift, y saber cuándo no dice nada.
- Encontrar qué evento suele venir después de otro, y en cuántos días.

Todas las respuestas de esta guía vienen de una corrida del cuaderno con los valores que trae por defecto. Los datos del curso son sintéticos, y los patrones de la bitácora se plantaron a propósito al crearlos para poder medirlos.

Paso 1 de 9 · ¿Qué hay en la bitácora?

Este lab trabaja con la bitácora de mantenimiento de 2024. Cada fila es un evento, como lo anota el turno, con la central, la fecha, el tipo de evento y cuántas horas duró.

Paso 1 de 9

```
# Paso 1
DATOS = ("https://raw.githubusercontent.com/RodrigoMSB/"
        "curso-python-minergia/main/datos/")
import pandas as pd

# La bitácora del año, un evento por fila, como la llena el turno.
mant = pd.read_csv(DATOS + "mantenimiento.csv", parse_dates=["fecha"])

print("Eventos del año", len(mant))
print("Centrales con eventos", mant["central"].nunique())
mant[["central", "fecha", "tipo_evento", "duracion_horas"]].head()
```

```
Eventos del año 600
Centrales con eventos 20
```

	central	fecha	tipo_evento	duracion_horas
0	Eólica Campo Abierto	2024-01-01	preventivo	5
1	Parque Solar Quebrada Honda	2024-01-01	preventivo	8
2	Parque Solar Llano Seco	2024-01-02	falla_mecanica	49
3	Parque Solar Quebrada Honda	2024-01-02	inspeccion	6
4	Central Tres Saltos	2024-01-03	correctivo	38

La bitácora tiene 600 eventos repartidos entre las 20 centrales del curso. La celda muestra solo cuatro columnas. El archivo trae además una columna con el texto libre que escribe el turno, que se usa en el Módulo 5.

En este lab no se suman megawatts. Se buscan patrones en los eventos, qué pasa junto y qué viene después de qué. Eso es la minería de datos.

Paso 2 de 9 · ¿Cuánto dura cada tipo de evento?

Antes de buscar patrones conviene conocer los seis tipos de evento.

Paso 2 de 9

```
# Paso 2
resumen = mant.groupby("tipo_evento")["duracion_horas"].agg(
    eventos="count",
    horas_promedio="mean",
    horas_maximo="max",
)
resumen.round(1).sort_values("eventos", ascending=False)
```

	eventos	horas_promedio	horas_maximo
tipo_evento			
preventivo	158	14.5	24
correctivo	118	38.9	72
inspeccion	99	4.7	8
falla_mecanica	98	50.6	94
evento_climatico	80	21.2	36
falla_electrica	47	22.4	48

El preventivo es el más frecuente, con 158 eventos, y es corto, 14.5 horas en promedio. La falla mecánica tiene 98 eventos pero es la que deja más tiempo detenida una central, 50.6 horas en promedio y hasta 94. La inspección es la más corta, menos de 5 horas.

La tabla usa agg con tres cálculos a la vez, igual que en el Lab 02. Contar y medir la duración por separado da dos lecturas distintas. Lo más frecuente no es lo que más cuesta.

Paso 3 de 9 · Tu turno, mira qué le pasa a cada tecnología

Un tipo de evento puede concentrarse en algunas centrales. Para saberlo hay que pegarle a cada evento la ficha de su central.

Paso 3 de 9

```
# Paso 3
tipo = "evento_climatico" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↵ "falla_electrica", "evento_climatico"]

# A cada evento se le pega la ficha de su central, como en el Lab 01.
centrales = pd.read_csv(DATOS + "centrales.csv")
con_ficha = pd.merge(mant, centrales, on="central", how="left")

elegidos = con_ficha[con_ficha["tipo_evento"] == tipo]
print(f"✓ Hay {len(elegidos)} eventos de tipo {tipo}")
elegidos["tecnologia"].value_counts()
```

```
✓ Hay 80 eventos de tipo evento_climatico
tecnologia
eolica      55
hidro       12
solar        6
gas          4
carbon       2
diesel       1
Name: count, dtype: int64
```

La celda une la bitácora con la tabla de centrales, como en el Lab 01, y se queda con los eventos del tipo elegido. Hay 80 eventos climáticos, y 55 son de centrales eólicas. Tiene sentido, el viento fuerte es lo que más afecta a un parque eólico.

Elige falla_electrica en la lista y vuelve a correr la celda para ver cómo se reparte otro tipo.

Paso 4 de 9 · ¿Qué le pasó a cada central en cada mes?

En un supermercado, cada boleta junta lo que compró una persona en una visita. Para buscar qué se compra junto, se comparan boletas. Con la bitácora se hace lo mismo.

Paso 4 de 9

```
# Paso 4
mant["mes"] = mant["fecha"].dt.month

# Se juntan los eventos de cada central y mes. set quita los repetidos
# y sorted los ordena por nombre.
canastas = mant.groupby(["central", "mes"])["tipo_evento"].apply(lambda s: sorted(set(s)))

print("✓ Canastas", len(canastas))
print("Eventos distintos por canasta, en promedio", round(canastas.apply(len).mean(), 1))
canastas.head(6).to_frame("lo_que_pasó")
```

```
✓ Canastas 215
Eventos distintos por canasta, en promedio 2.2
```

central	mes	lo_que_pasó
Carboeléctrica Costa Brava	1	[preventivo]
	2	[falla_electrica, preventivo]
	3	[correctivo, inspeccion]
	4	[preventivo]
	5	[correctivo, evento_climatico]
	6	[correctivo, falla_mecanica]

Cada **canasta** es todo lo que le pasó a una central en un mes. La celda junta los eventos de cada central y mes, quita los repetidos con set y los ordena con sorted. Quedan 215 canastas, con 2.2 tipos de evento distintos en promedio.

La primera canasta de la Carboeléctrica Costa Brava tiene solo un preventivo. En febrero tuvo una falla eléctrica y un preventivo. Elegir qué es una canasta es una decisión. Con canastas más grandes, por ejemplo un trimestre, casi todo aparece con todo.

Paso 5 de 9 · ¿En cuántas canastas aparece cada evento?

Para comparar canastas conviene una tabla de sí o no. Una fila por canasta, una columna por tipo de evento, y en cada casilla si ese evento ocurrió o no.

Paso 5 de 9

```
# Paso 5
# crosstab cuenta los eventos de cada canasta y > 0 lo convierte en sí o no.
tabla = pd.crosstab([mant["central"], mant["mes"]], mant["tipo_evento"]) > 0
print("Canastas", tabla.shape[0], " tipos de evento", tabla.shape[1])

# El promedio de una columna de sí o no es la proporción de sí.
print()
print("Porcentaje de canastas donde aparece cada tipo")
print((100 * tabla.mean()).round(1).sort_values(ascending=False))

tabla.head(6).map(lambda v: "✓" if v else "")
```

Canastas 215 tipos de evento 6

Porcentaje de canastas donde aparece cada tipo

tipo_evento	
preventivo	56.3
correctivo	40.0
inspeccion	39.5
falla_mecanica	36.3
evento_climatico	25.6
falla_electrica	19.5

dtype: float64

tipo_evento		correctivo	evento_climatico	falla_electrica	\
central	mes				
Carboeléctrica Costa Brava	1				
	2				✓
	3	✓			
	4				
	5	✓	✓		
	6	✓			

tipo_evento		falla_mecanica	inspeccion	preventivo
central	mes			
Carboeléctrica Costa Brava	1			✓
	2			✓
	3		✓	
	4			✓
	5			
	6	✓		

crosstab cuenta los eventos de cada canasta y > 0 los convierte en sí o no. Son 215 canastas y 6 tipos de evento.

El promedio de una columna de sí o no es la proporción de sí. El preventivo aparece en el 56.3 por ciento de las canastas, el correctivo en el 40.0 y la falla eléctrica en el 19.5. Ese porcentaje es lo normal de cada evento, y es el punto de comparación del paso siguiente.

En la tabla de abajo, un ✓ marca los eventos que ocurrieron en cada canasta. En esta guía la tabla sale en dos bloques porque es más ancha que la hoja.

Paso 6 de 9 · Tu turno, si pasa una cosa, ¿pasa la otra?

Una regla dice si pasa esto, entonces pasa esto otro. Se mide con dos números, la confianza y el lift.

Paso 6 de 9

```
# Paso 6
si = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪ "falla_electrica", "evento_climatico"]
entonces = "correctivo" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪ "falla_electrica", "evento_climatico"]

if si == entonces:
    print("Elige dos eventos distintos")
else:
    con_si = tabla[si].sum()
    con_los_dos = (tabla[si] & tabla[entonces]).sum()

    # Confianza, de las canastas con si, cuántas tienen también entonces.
    confianza = 100 * con_los_dos / con_si
    # Lo normal, en cuántas canastas aparece entonces, haya o no haya si.
    normal = 100 * tabla[entonces].mean()
    # Lift, cuántas veces más de lo normal. Sobre 1 van juntos, cerca de 1 no hay relación.
    lift = confianza / normal

    print(f"Canastas con {si}", con_si)
    print(f"De ellas, también con {entonces}", con_los_dos)
    print(f"Confianza {confianza:.1f} por ciento")
    print(f"{entonces} aparece en general en el {normal:.1f} por ciento")
    print(f"Lift {lift:.2f}")
```

```
Canastas con falla_electrica 42
De ellas, también con correctivo 35
Confianza 83.3 por ciento
correctivo aparece en general en el 40.0 por ciento
Lift 2.08
```

La **confianza** dice de las canastas que tienen el primer evento, cuántas tienen también el segundo. Hay 42 canastas con falla eléctrica, y 35 de ellas tienen también un correctivo. La confianza es 83.3 por ciento.

El **lift** compara esa confianza con lo normal. El correctivo aparece en el 40.0 por ciento de todas las canastas. Con falla eléctrica aparece en el 83.3, o sea 2.08 veces más de lo normal. Un lift sobre 1 quiere decir que van juntos. Cerca de 1, que no hay relación.

Prueba falla_electrica con preventivo. La confianza es 52.4 por ciento, que parece mucho, pero el lift es 0.93. El preventivo aparece en más de la mitad de las canastas, haya o no falla eléctrica. Si eliges el mismo evento en las dos listas, la celda pide elegir dos distintos.

Paso 7 de 9 · ¿Qué parejas de eventos van juntas?

Probar las parejas de a una es lento. La celda hace el mismo cálculo del Paso 6 para todas las combinaciones.

Paso 7 de 9

```
# Paso 7
# El mismo cálculo del Paso 6 para todas las parejas posibles.
filas = []
for si in tabla.columns:
    for entonces in tabla.columns:
        if si != entonces:
            juntos = (tabla[si] & tabla[entonces]).sum()
            confianza = juntos / tabla[si].sum()
            filas.append({"si": si, "entonces": entonces, "canastas": juntos,
                          "confianza": round(100 * confianza, 1),
                          "lift": round(confianza / tabla[entonces].mean(), 2)})

reglas = pd.DataFrame(filas)
print("✓ Parejas revisadas", len(reglas))
reglas.sort_values("confianza", ascending=False).head(6)
```

```
✓ Parejas revisadas 30
      si      entonces  canastas  confianza  lift
10 falla_electrica  correctivo      35      83.3  2.08
7  evento_climatico falla_mecanica     38      69.1  1.90
14 falla_electrica  preventivo      22      52.4  0.93
9  evento_climatico  preventivo      28      50.9  0.90
24 inspeccion      preventivo      43      50.6  0.90
16 falla_mecanica  evento_climatico     38      48.7  1.90
```

Con seis tipos de evento hay 30 parejas, porque cada evento puede ir en si o en entonces. La tabla muestra las seis con más confianza.

Las dos primeras sí dicen algo. Falla eléctrica con correctivo tiene 83.3 de confianza y lift 2.08. Evento climático con falla mecánica tiene 69.1 y lift 1.90. La tercera, falla eléctrica con preventivo, tiene 52.4 de confianza pero lift 0.93, así que no dice nada.

UNA CONFIANZA ALTA NO BASTA

Falla eléctrica con preventivo tiene un 52,4 por ciento de confianza y parece una regla. Pero el preventivo aparece en el 56,3 por ciento de todas las canastas. Su lift es 0,93, o sea que no aparece más de lo normal. Las dos reglas que sí dicen algo tienen lift cercano a 2. Que dos eventos vayan juntos no prueba que uno cause el otro.

Paso 8 de 9 · Tu turno, ¿qué viene después de cada evento?

Las canastas no saben de orden. Dentro de un mes da lo mismo qué pasó primero. Este paso mira el orden en el tiempo.

Paso 8 de 9

```
# Paso 8
evento = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↵ "falla_electrica", "evento_climatico"]

# Se ordena por central y fecha, y shift(-1) trae el evento de la fila siguiente.
ordenados = mant.sort_values(["central", "fecha"]).copy()
ordenados["siguiente"] = ordenados.groupby("central")["tipo_evento"].shift(-1)

# normalize="index" deja cada fila en proporciones que suman uno.
transicion = pd.crosstab(ordenados["tipo_evento"], ordenados["siguiente"],
                        normalize="index")

print(f"Después de {evento}, el evento siguiente en la misma central, en porcentaje")
(100 * transicion.loc[evento]).round(1).sort_values(ascending=False)
```

```
Después de falla_electrica, el evento siguiente en la misma central, en porcentaje
siguiente
correctivo          78.7
preventivo          10.6
falla_electrica      6.4
inspeccion           4.3
evento_climatico     0.0
falla_mecanica       0.0
Name: falla_electrica, dtype: float64
```

La celda ordena la bitácora por central y fecha, y `shift(-1)` trae a cada fila el evento siguiente de la misma central. Después cuenta, para cada evento, cuál vino después, en porcentaje.

Después de una falla eléctrica, el evento siguiente en la misma central es un correctivo en el 78.7 por ciento de los casos. Elige `evento_climatico` y vuelve a correr la celda. Lo que viene después es una falla mecánica en el 60.3 por ciento. Con preventivo no hay un siguiente que destaque, ninguno llega al 30 por ciento.

Paso 9 de 9 · Tu turno, ¿en cuántos días llega el correctivo?

Saber que después de una falla eléctrica viene un correctivo no basta para programar cuadrillas. Hay que saber en cuántos días.

Paso 9 de 9

```
# Paso 9
dias = 3 #@param {type:"slider", min:0, max:7, step:1}

electricas = mant[mant["tipo_evento"] == "falla_electrica"]
correctivos = mant[mant["tipo_evento"] == "correctivo"]

# Cada falla eléctrica se junta con todos los correctivos de su misma central.
pares = pd.merge(electricas[["central", "fecha"]], correctivos[["central", "fecha"]],
                  on="central", suffixes=("_falla", "_correctivo"))
distancia = (pares["fecha_correctivo"] - pares["fecha_falla"]).dt.days

# Se quedan los correctivos que llegan el mismo día o hasta días después.
cerca = pares[(distancia >= 0) & (distancia <= dias)]
con_correctivo = cerca[["central", "fecha_falla"]].drop_duplicates()
porcentaje = 100 * len(con_correctivo) / len(electricas)

print("Fallas eléctricas", len(electricas))
print(f"Con un correctivo dentro de {dias} días", len(con_correctivo))
print(f"Medido {porcentaje:.1f} por ciento")
print("Lo que se plantó al crear los datos, 70 por ciento")
```

```
Fallas eléctricas 47
Con un correctivo dentro de 3 días 34
Medido 72.3 por ciento
Lo que se plantó al crear los datos, 70 por ciento
```

La celda junta cada falla eléctrica con todos los correctivos de su misma central y calcula la distancia en días. Después cuenta las fallas que tienen un correctivo el mismo día o hasta los días del deslizador. Con 3 días, 34 de las 47 fallas eléctricas tienen un correctivo, el 72.3 por ciento. Al crear los datos del curso se plantó un 70 por ciento, así que la medición está cerca.

Mueve el deslizador. Con 0 días, el mismo día, son 7 fallas y el 14.9 por ciento. Con 1 día son 19 y el 40.4. Con 7 días son otra vez 34 y el 72.3, no sube más.

LA VENTANA LA DECIDE QUIEN ANALIZA

Con 0 días da 14,9 por ciento y con 3 días da 72,3. Desde los 3 días ya no sube más, porque así se crearon los datos. En un informe se escribe la ventana que se usó, porque cambia el resultado. Estos datos son inventados y el patrón se plantó a propósito para poder medirlo.

Para seguir practicando

Al final del cuaderno hay cuatro ejercicios para quien quiera seguir después de clase. En ellos sí se escribe código. Antes de empezar hay que correr todo el cuaderno con Entorno de ejecución, Ejecutar todo, porque los ejercicios usan las tablas de los pasos.

Cada ejercicio tiene una celda vacía para escribir la respuesta y una solución plegada, que conviene abrir solo después de intentarlo. Las soluciones no están en esta guía.

- **Ejercicio 1.** Armar las canastas por trimestre en vez de por mes y ver qué pasa con los porcentajes.
- **Ejercicio 2.** Buscar qué eventos anuncian un correctivo.
- **Ejercicio 3.** Medir el segundo patrón plantado, el clima y las fallas mecánicas el mismo día.
- **Ejercicio 4.** Buscar qué central se parece a cuál por la forma de su día.

Para repasar

Referencia rápida

Lo que se escribe	Para qué sirve
<code>groupby(...).agg(...)</code>	Varios cálculos por grupo
<code>value_counts()</code>	Cuántas veces aparece cada valor
<code>dt.month · dt.quarter</code>	El mes o el trimestre de una fecha
<code>pd.crosstab(filas, columnas)</code>	Cuenta las combinaciones de dos columnas
<code>tabla > 0</code>	Convierte los conteos en sí o no
<code>tabla[a] & tabla[b]</code>	Las canastas que tienen los dos eventos
<code>shift(-1)</code>	Trae el valor de la fila siguiente
<code>.dt.days</code>	La distancia entre dos fechas, en días

Si algo sale mal

Lo que aparece en pantalla	Qué pasó
<code>NameError: name 'mant' is not defined</code>	Corriste un paso sin correr antes el Paso 1, que es el que lee la bitácora.
<code>NameError: name 'tabla' is not defined</code>	El Paso 6 y el Paso 7 usan la tabla de sí o no que arma el Paso 5. Corre el Paso 5 antes.
Aparece Elige dos eventos distintos	No es un error. En el Paso 6 elegiste el mismo evento en las dos listas.
La respuesta no cambió después de cambiar la lista o el deslizador	Cambiar un campo no corre la celda. Hay que volver a apretar el botón de play.

Tres preguntas de repaso

1. Qué es una canasta en este lab

Todo lo que le pasó a una central en un mes, como una boleta con las compras de una visita al supermercado.

2. Por qué una confianza de 52,4 por ciento puede no decir nada

Porque el segundo evento ya aparece en más de la mitad de las canastas. El lift cercano a 1 dice que no aparece más de lo normal.

3. Por qué hay que escribir la ventana de días en un informe

Porque el resultado cambia con la ventana. Con 0 días da 14,9 por ciento y con 3 días da 72,3.

El Lab 04 guiado en una plana

Para imprimir y tener al lado durante el curso

Los nueve pasos

Paso	La pregunta	La idea
1	¿Qué hay en la bitácora?	Un evento por fila
2	¿Cuánto dura cada tipo de evento?	Contar y medir duración
3	Tu turno, mira qué le pasa a cada tecnología	Pegar la ficha y contar
4	¿Qué le pasó a cada central en cada mes?	Canastas
5	¿En cuántas canastas aparece cada evento?	Tabla de sí o no
6	Tu turno, si pasa una cosa, ¿pasa la otra?	Confianza y lift
7	¿Qué parejas de eventos van juntas?	Todas las reglas a la vez
8	Tu turno, ¿qué viene después de cada evento?	El orden en el tiempo
9	Tu turno, ¿en cuántos días llega el correctivo?	La ventana de días

Cómo se lee una regla

Confianza	De las canastas con el primero, cuántas tienen el segundo
Lo normal	En cuántas canastas aparece el segundo, en general
Lift	Confianza dividida por lo normal
Lift sobre 1	Van juntos más de lo normal
Lift cerca de 1	No hay relación, aunque la confianza sea alta
Ir juntos	No prueba que uno cause el otro

Las distancias entre perfiles, los algoritmos apriori y FP-Growth y las reglas con más de un evento están en la ruta completa de este módulo.