# Guía del alumno

## Módulo 4, Minería de datos

Ruta guiada

Análisis Avanzado de Datos con Python

### Cómo usar esta guía

Esta guía acompaña al Lab 04 guiado y sigue sus dos partes en el mismo orden y con los mismos nombres del cuaderno. La Parte 1, En clase, tiene cinco pasos, de Paso 1 de 5 a Paso 5 de 5, y se hace en clase. La Parte 2, Para estudiar, tiene cuatro estudios, de Estudio 1 de 4 a Estudio 4 de 4, y se hace después de clase con esta guía, una vez corrida la Parte 1. Cada paso trae el código y la respuesta tal como aparecen en Colab, y una explicación en palabras simples.

En los pasos no hay que escribir código. Lo que cambia se cambia en las listas desplegables y en el deslizador, y después se vuelve a correr la celda. El lab responde tres preguntas. Cómo se convierte una bitácora de eventos en canastas que se pueden comparar, cómo se mide si dos eventos aparecen juntos más de lo normal, y qué evento suele venir después de otro, y en cuántos días.

### Lo que vas a poder hacer al terminar

- Resumir una bitácora de eventos por tipo, contando y midiendo duración.
- Agrupar los eventos en canastas, como boletas de supermercado.
- Calcular qué tan común es cada evento en las canastas.
- Medir una regla con la confianza y el lift, y saber cuándo no dice nada.
- Encontrar qué evento suele venir después de otro, y en cuántos días.

Todas las respuestas de esta guía vienen de una corrida del cuaderno con los valores que trae por defecto. Los datos del curso son sintéticos, y los patrones de la bitácora se plantaron a propósito al crearlos para poder medirlos.

# Parte 1 · En clase

Cinco pasos, uno detrás del otro, que se hacen en clase en el mismo orden del cuaderno.

## Paso 1 de 5 · ¿Qué hay en la bitácora?

Este lab trabaja con la bitácora de mantenimiento de 2024. Cada fila es un evento, como lo anota el turno, con la central, la fecha, el tipo de evento y cuántas horas duró.

### Paso 1 de 5

```
# Paso 1
DATOS = ("https://raw.githubusercontent.com/RodrigoMSB/"
         "curso-python-minergia/main/datos/")
import pandas as pd

# La bitácora del año, un evento por fila, como la llena el turno.
mant = pd.read_csv(DATOS + "mantenimiento.csv", parse_dates=["fecha"])

print("Eventos del año", len(mant))
print("Centrales con eventos", mant["central"].nunique())
mant[["central", "fecha", "tipo_evento", "duracion_horas"]].head()
```

```
Eventos del año 600
Centrales con eventos 20
                      central      fecha     tipo_evento  duracion_horas
0         Eólica Campo Abierto 2024-01-01      preventivo               5
1  Parque Solar Quebrada Honda 2024-01-01      preventivo               8
2      Parque Solar Llano Seco 2024-01-02  falla_mecanica              49
3  Parque Solar Quebrada Honda 2024-01-02      inspeccion               6
4          Central Tres Saltos 2024-01-03      correctivo              38
```

La bitácora tiene 600 eventos repartidos entre las 20 centrales del curso. La celda muestra solo cuatro columnas. El archivo trae además una columna con el texto libre que escribe el turno, que se usa en el Módulo 5.

En este lab no se suman megawatts. Se buscan patrones en los eventos, qué pasa junto y qué viene después de qué. Eso es la minería de datos.

## Paso 2 de 5 · ¿Qué le pasó a cada central en cada mes?

En un supermercado, cada boleta junta lo que compró una persona en una visita. Para buscar qué se compra junto, se comparan boletas. Con la bitácora se hace lo mismo.

### Paso 2 de 5

```
# Paso 2
mant["mes"] = mant["fecha"].dt.month

# Se juntan los eventos de cada central y mes. set quita los repetidos
# y sorted los ordena por nombre.
canastas = mant.groupby(["central", "mes"])["tipo_evento"].apply(lambda s: sorted(set(s)))

print("✓ Canastas", len(canastas))
print("Eventos distintos por canasta, en promedio", round(canastas.apply(len).mean(), 1))
canastas.head(6).to_frame("lo_que_pasó")
```

```
✓ Canastas 215
Eventos distintos por canasta, en promedio 2.2
                                                    lo_que_pasó
central                    mes
Carboeléctrica Costa Brava 1                       [preventivo]
                           2     [falla_electrica, preventivo]
                           3          [correctivo, inspeccion]
                           4                       [preventivo]
                           5    [correctivo, evento_climatico]
                           6      [correctivo, falla_mecanica]
```

Cada **canasta** es todo lo que le pasó a una central en un mes. La celda junta los eventos de cada central y mes, quita los repetidos con `set` y los ordena con `sorted`. Quedan 215 canastas, con 2.2 tipos de evento distintos en promedio.

La primera canasta de la Carboeléctrica Costa Brava tiene solo un preventivo. En febrero tuvo una falla eléctrica y un preventivo. Elegir qué es una canasta es una decisión. Con canastas más grandes, por ejemplo un trimestre, casi todo aparece con todo.

## Paso 3 de 5 · ¿En cuántas canastas aparece cada evento?

Para comparar canastas conviene una tabla de sí o no. Una fila por canasta, una columna por tipo de evento, y en cada casilla si ese evento ocurrió o no.

### Paso 3 de 5

```
# Paso 3
# crosstab cuenta los eventos de cada canasta y > 0 lo convierte en sí o no.
tabla = pd.crosstab([mant["central"], mant["mes"]], mant["tipo_evento"]) > 0
print("Canastas", tabla.shape[0], " tipos de evento", tabla.shape[1])

# El promedio de una columna de sí o no es la proporción de sí.
print()
print("Porcentaje de canastas donde aparece cada tipo")
print((100 * tabla.mean()).round(1).sort_values(ascending=False))

tabla.head(6).map(lambda v: "✓" if v else "")
```

```
Canastas 215  tipos de evento 6

Porcentaje de canastas donde aparece cada tipo
tipo_evento
preventivo          56.3
correctivo          40.0
inspeccion          39.5
falla_mecanica      36.3
evento_climatico    25.6
falla_electrica     19.5
dtype: float64
tipo_evento                  correctivo evento_climatico falla_electrica  \
central                  mes
Carboeléctrica Costa Brava 1
                           2                                          ✓
                           3           ✓
                           4
                           5           ✓               ✓
                           6           ✓

tipo_evento                  falla_mecanica inspeccion preventivo
central                  mes
Carboeléctrica Costa Brava 1                                    ✓
                           2                                    ✓
                           3                           ✓
                           4                                    ✓
                           5
                           6               ✓
```

`crosstab` cuenta los eventos de cada canasta y `> 0` los convierte en sí o no. Son 215 canastas y 6 tipos de evento.

El promedio de una columna de sí o no es la proporción de sí. El preventivo aparece en el 56.3 por ciento de las canastas, el correctivo en el 40.0 y la falla eléctrica en el 19.5. Ese porcentaje es lo normal de cada evento, y es el punto de comparación del paso siguiente.

En la tabla de abajo, un ✓ marca los eventos que ocurrieron en cada canasta. En esta guía la tabla sale en dos bloques porque es más ancha que la hoja.

## Paso 4 de 5 · Tu turno, si pasa una cosa, ¿pasa la otra?

Una regla dice si pasa esto, entonces pasa esto otro. Se mide con dos números, la confianza y el lift.

### Paso 4 de 5

```
# Paso 4
si = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]
entonces = "correctivo" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

if si == entonces:
    print("Elige dos eventos distintos")
else:
    con_si = tabla[si].sum()
    con_los_dos = (tabla[si] & tabla[entonces]).sum()

    # Confianza, de las canastas con si, cuántas tienen también entonces.
    confianza = 100 * con_los_dos / con_si
    # Lo normal, en cuántas canastas aparece entonces, haya o no haya si.
    normal = 100 * tabla[entonces].mean()
    # Lift, cuántas veces más de lo normal. Sobre 1 van juntos, cerca de 1 no hay relación.
    lift = confianza / normal

    print(f"Canastas con {si}", con_si)
    print(f"De ellas, también con {entonces}", con_los_dos)
    print(f"Confianza  {confianza:.1f} por ciento")
    print(f"{entonces} aparece en general en el {normal:.1f} por ciento")
    print(f"Lift  {lift:.2f}")
```

```
Canastas con falla_electrica 42
De ellas, también con correctivo 35
Confianza  83.3 por ciento
correctivo aparece en general en el 40.0 por ciento
Lift  2.08
```

La **confianza** dice de las canastas que tienen el primer evento, cuántas tienen también el segundo. Hay 42 canastas con falla eléctrica, y 35 de ellas tienen también un correctivo. La confianza es 83.3 por ciento.

El **lift** compara esa confianza con lo normal. El correctivo aparece en el 40.0 por ciento de todas las canastas. Con falla eléctrica aparece en el 83.3, o sea 2.08 veces más de lo normal. Un lift sobre 1 quiere decir que van juntos. Cerca de 1, que no hay relación.

Prueba falla_electrica con preventivo. La confianza es 52.4 por ciento, que parece mucho, pero el lift es 0.93. El preventivo aparece en más de la mitad de las canastas, haya o no falla eléctrica. Si eliges el mismo evento en las dos listas, la celda pide elegir dos distintos.

## Paso 5 de 5 · Tu turno, ¿en cuántos días llega el correctivo?

Saber que después de una falla eléctrica viene un correctivo no basta para programar cuadrillas. Hay que saber en cuántos días.

### Paso 5 de 5

```
# Paso 5
dias = 3 #@param {type:"slider", min:0, max:7, step:1}

electricas = mant[mant["tipo_evento"] == "falla_electrica"]
correctivos = mant[mant["tipo_evento"] == "correctivo"]

# Cada falla eléctrica se junta con todos los correctivos de su misma central.
pares = pd.merge(electricas[["central", "fecha"]], correctivos[["central", "fecha"]],
                 on="central", suffixes=("_falla", "_correctivo"))
distancia = (pares["fecha_correctivo"] - pares["fecha_falla"]).dt.days

# Se quedan los correctivos que llegan el mismo día o hasta dias después.
cerca = pares[(distancia >= 0) & (distancia <= dias)]
con_correctivo = cerca[["central", "fecha_falla"]].drop_duplicates()
porcentaje = 100 * len(con_correctivo) / len(electricas)

print("Fallas eléctricas", len(electricas))
print(f"Con un correctivo dentro de {dias} días", len(con_correctivo))
print(f"Medido {porcentaje:.1f} por ciento")
print("Lo que se plantó al crear los datos, 70 por ciento")
```

```
Fallas eléctricas 47
Con un correctivo dentro de 3 días 34
Medido 72.3 por ciento
Lo que se plantó al crear los datos, 70 por ciento
```

La celda junta cada falla eléctrica con todos los correctivos de su misma central y calcula la distancia en días. Después cuenta las fallas que tienen un correctivo el mismo día o hasta los días del deslizador.

Con 3 días, 34 de las 47 fallas eléctricas tienen un correctivo, el 72.3 por ciento. Al crear los datos del curso se plantó un 70 por ciento, así que la medición está cerca.

Mueve el deslizador. Con 0 días, el mismo día, son 7 fallas y el 14.9 por ciento. Con 1 día son 19 y el 40.4. Con 7 días son otra vez 34 y el 72.3, no sube más.

> **LA VENTANA LA DECIDE QUIEN ANALIZA**
>
> Con 0 días da 14,9 por ciento y con 3 días da 72,3. Desde los 3 días ya no sube más, porque así se crearon los datos. En un informe se escribe la ventana que se usó, porque cambia el resultado. Estos datos son inventados y el patrón se plantó a propósito para poder medirlo.

# Parte 2 · Para estudiar

Estos pasos se hacen después de clase, con esta guía. Antes de empezar hay que correr toda la Parte 1 del cuaderno, porque los estudios usan sus tablas.

## Estudio 1 de 4 · ¿Cuánto dura cada tipo de evento?

Antes de buscar patrones conviene conocer los seis tipos de evento.

### Estudio 1 de 4

```
# Estudio 1
resumen = mant.groupby("tipo_evento")["duracion_horas"].agg(
    eventos="count",
    horas_promedio="mean",
    horas_maximo="max",
)
resumen.round(1).sort_values("eventos", ascending=False)
```

```
                eventos  horas_promedio  horas_maximo
tipo_evento
preventivo          158            14.5            24
correctivo          118            38.9            72
inspeccion           99             4.7             8
falla_mecanica       98            50.6            94
evento_climatico     80            21.2            36
falla_electrica      47            22.4            48
```

El preventivo es el más frecuente, con 158 eventos, y es corto, 14.5 horas en promedio. La falla mecánica tiene 98 eventos pero es la que deja más tiempo detenida una central, 50.6 horas en promedio y hasta 94. La inspección es la más corta, menos de 5 horas.

La tabla usa `agg` con tres cálculos a la vez, igual que en el Lab 02. Contar y medir la duración por separado da dos lecturas distintas. Lo más frecuente no es lo que más cuesta.

## Estudio 2 de 4 · Tu turno, mira qué le pasa a cada tecnología

Un tipo de evento puede concentrarse en algunas centrales. Para saberlo hay que pegarle a cada evento la ficha de su central.

### Estudio 2 de 4

```
# Estudio 2
tipo = "evento_climatico" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# A cada evento se le pega la ficha de su central, como en el Lab 01.
centrales = pd.read_csv(DATOS + "centrales.csv")
con_ficha = pd.merge(mant, centrales, on="central", how="left")

elegidos = con_ficha[con_ficha["tipo_evento"] == tipo]
print(f"✓ Hay {len(elegidos)} eventos de tipo {tipo}")
elegidos["tecnologia"].value_counts()
```

```
✓ Hay 80 eventos de tipo evento_climatico
tecnologia
eolica    55
hidro     12
solar      6
gas        4
carbon     2
diesel     1
Name: count, dtype: int64
```

La celda une la bitácora con la tabla de centrales, como en el Lab 01, y se queda con los eventos del tipo elegido. Hay 80 eventos climáticos, y 55 son de centrales eólicas. Tiene sentido, el viento fuerte es lo que más afecta a un parque eólico.

Elige falla_electrica en la lista y vuelve a correr la celda para ver cómo se reparte otro tipo.

## Estudio 3 de 4 · ¿Qué parejas de eventos van juntas?

Probar las parejas de a una es lento. La celda hace el mismo cálculo del Paso 4 para todas las combinaciones.

### Estudio 3 de 4

```
# Estudio 3
# El mismo cálculo del Paso 4 para todas las parejas posibles.
filas = []
for si in tabla.columns:
    for entonces in tabla.columns:
        if si != entonces:
            juntos = (tabla[si] & tabla[entonces]).sum()
            confianza = juntos / tabla[si].sum()
            filas.append({"si": si, "entonces": entonces, "canastas": juntos,
                          "confianza": round(100 * confianza, 1),
                          "lift": round(confianza / tabla[entonces].mean(), 2)})

reglas = pd.DataFrame(filas)
print("✓ Parejas revisadas", len(reglas))
reglas.sort_values("confianza", ascending=False).head(6)
```

```
✓ Parejas revisadas 30
                 si          entonces  canastas  confianza  lift
10   falla_electrica        correctivo        35       83.3  2.08
7   evento_climatico    falla_mecanica        38       69.1  1.90
14   falla_electrica        preventivo        22       52.4  0.93
9   evento_climatico        preventivo        28       50.9  0.90
24        inspeccion        preventivo        43       50.6  0.90
16    falla_mecanica  evento_climatico        38       48.7  1.90
```

Con seis tipos de evento hay 30 parejas, porque cada evento puede ir en si o en entonces. La tabla muestra las seis con más confianza.

Las dos primeras sí dicen algo. Falla eléctrica con correctivo tiene 83.3 de confianza y lift 2.08. Evento climático con falla mecánica tiene 69.1 y lift 1.90. La tercera, falla eléctrica con preventivo, tiene 52.4 de confianza pero lift 0.93, así que no dice nada.

> **UNA CONFIANZA ALTA NO BASTA**
>
> Falla eléctrica con preventivo tiene un 52,4 por ciento de confianza y parece una regla. Pero el preventivo aparece en el 56,3 por ciento de todas las canastas. Su lift es 0,93, o sea que no aparece más de lo normal. Las dos reglas que sí dicen algo tienen lift cercano a 2. Que dos eventos vayan juntos no prueba que uno cause el otro.

## Estudio 4 de 4 · Tu turno, ¿qué viene después de cada evento?

Las canastas no saben de orden. Dentro de un mes da lo mismo qué pasó primero. Este paso mira el orden en el tiempo.

### Estudio 4 de 4

```
# Estudio 4
evento = "falla_electrica" #@param ["preventivo", "correctivo", "inspeccion", "falla_mecanica",
↪  "falla_electrica", "evento_climatico"]

# Se ordena por central y fecha, y shift(-1) trae el evento de la fila siguiente.
ordenados = mant.sort_values(["central", "fecha"]).copy()
ordenados["siguiente"] = ordenados.groupby("central")["tipo_evento"].shift(-1)

# normalize="index" deja cada fila en proporciones que suman uno.
transicion = pd.crosstab(ordenados["tipo_evento"], ordenados["siguiente"],
                         normalize="index")

print(f"Después de {evento}, el evento siguiente en la misma central, en porcentaje")
(100 * transicion.loc[evento]).round(1).sort_values(ascending=False)
```

```
Después de falla_electrica, el evento siguiente en la misma central, en porcentaje
siguiente
correctivo          78.7
preventivo          10.6
falla_electrica      6.4
inspeccion           4.3
evento_climatico     0.0
falla_mecanica       0.0
Name: falla_electrica, dtype: float64
```

La celda ordena la bitácora por central y fecha, y `shift(-1)` trae a cada fila el evento siguiente de la misma central. Después cuenta, para cada evento, cuál vino después, en porcentaje.

Después de una falla eléctrica, el evento siguiente en la misma central es un correctivo en el 78.7 por ciento de los casos. Elige evento_climatico y vuelve a correr la celda. Lo que viene después es una falla mecánica en el 60.3 por ciento. Con preventivo no hay un siguiente que destaque, ninguno llega al 30 por ciento.

## Para seguir practicando

Al final del cuaderno hay cuatro ejercicios para quien quiera seguir después de clase. En ellos sí se escribe código. Antes de empezar hay que correr todo el cuaderno con Entorno de ejecución, Ejecutar todo, porque los ejercicios usan las tablas de los pasos.

Cada ejercicio tiene una celda vacía para escribir la respuesta y una solución plegada, que conviene abrir solo después de intentarlo. Las soluciones no están en esta guía.

- **Ejercicio 1.** Armar las canastas por trimestre en vez de por mes y ver qué pasa con los porcentajes.
- **Ejercicio 2.** Buscar qué eventos anuncian un correctivo.
- **Ejercicio 3.** Medir el segundo patrón plantado, el clima y las fallas mecánicas el mismo día.
- **Ejercicio 4.** Buscar qué central se parece a cuál por la forma de su día.

# Para repasar

## Referencia rápida

| Lo que se escribe | Para qué sirve |
|---|---|
| `groupby(...).agg(...)` | Varios cálculos por grupo |
| `value_counts()` | Cuántas veces aparece cada valor |
| `dt.month` · `dt.quarter` | El mes o el trimestre de una fecha |
| `pd.crosstab(filas, columnas)` | Cuenta las combinaciones de dos columnas |
| `tabla > 0` | Convierte los conteos en sí o no |
| `tabla[a] & tabla[b]` | Las canastas que tienen los dos eventos |
| `shift(-1)` | Trae el valor de la fila siguiente |
| `.dt.days` | La distancia entre dos fechas, en días |

## Si algo sale mal

| Lo que aparece en pantalla | Qué pasó |
|---|---|
| `NameError: name 'mant' is not defined` | Corriste un paso sin correr antes el Paso 1, que es el que lee la bitácora. |
| `NameError: name 'tabla' is not defined` | El Paso 4 y el Estudio 3 usan la tabla de sí o no que arma el Paso 3. Corre el Paso 3 antes. |
| Aparece Elige dos eventos distintos | No es un error. En el Paso 4 elegiste el mismo evento en las dos listas. |
| La respuesta no cambió después de cambiar la lista o el deslizador | Cambiar un campo no corre la celda. Hay que volver a apretar el botón de play. |

## Tres preguntas de repaso

#### 1. Qué es una canasta en este lab

Todo lo que le pasó a una central en un mes, como una boleta con las compras de una visita al supermercado.

#### 2. Por qué una confianza de 52,4 por ciento puede no decir nada

Porque el segundo evento ya aparece en más de la mitad de las canastas. El lift cercano a 1 dice que no aparece más de lo normal.

#### 3. Por qué hay que escribir la ventana de días en un informe

Porque el resultado cambia con la ventana. Con 0 días da 14,9 por ciento y con 3 días da 72,3.

# El Lab 04 guiado en una plana

Para imprimir y tener al lado durante el curso

## Los pasos de las dos partes

| N. | La pregunta | La idea |
|---|---|---|
| *Parte 1, en clase* | | |
| 1 | ¿Qué hay en la bitácora? | Un evento por fila |
| 2 | ¿Qué le pasó a cada central en cada mes? | Canastas |
| 3 | ¿En cuántas canastas aparece cada evento? | Tabla de sí o no |
| 4 | Tu turno, si pasa una cosa, ¿pasa la otra? | Confianza y lift |
| 5 | Tu turno, ¿en cuántos días llega el correctivo? | La ventana de días |
| *Parte 2, para estudiar* | | |
| 1 | ¿Cuánto dura cada tipo de evento? | Contar y medir duración |
| 2 | Tu turno, mira qué le pasa a cada tecnología | Pegar la ficha y contar |
| 3 | ¿Qué parejas de eventos van juntas? | Todas las reglas a la vez |
| 4 | Tu turno, ¿qué viene después de cada evento? | El orden en el tiempo |

## Cómo se lee una regla

| | |
|---|---|
| Confianza | De las canastas con el primero, cuántas tienen el segundo |
| Lo normal | En cuántas canastas aparece el segundo, en general |
| Lift | Confianza dividida por lo normal |
| Lift sobre 1 | Van juntos más de lo normal |
| Lift cerca de 1 | No hay relación, aunque la confianza sea alta |
| Ir juntos | No prueba que uno cause el otro |

Las distancias entre perfiles, los algoritmos apriori y FP-Growth y las reglas con más de un evento están en la ruta completa de este módulo.