

Guía del alumno

Caso integrador

Análisis Avanzado de Datos con Python

Cómo usar esta guía

Esta guía es para después de la sesión. Trae una solución completa del caso, con el código y las cifras exactas, y sobre todo con el razonamiento de por qué cada decisión se tomó así.

No es la única solución posible ni la correcta. Es una defendible. Si la tuya llegó a otros números, lo primero que conviene revisar es la corrección por el número de días, que es donde casi todos se separan.

El encargo, otra vez


Es enero de 2026. Llega el archivo del año 2025 y la jefatura pide un informe de una página, para el jueves, con tres respuestas.

1. Cómo se comportó la demanda en 2025 respecto de 2024, y si el crecimiento fue parejo.
2. Qué cambió en la generación.
3. Si hay algo en la bitácora de mantenimiento que valga la pena mirar.

Más una condición que no está escrita en el correo y se da por supuesta. Todo lo que afirmes tiene que poder rehacerse.

Todas las cifras y figuras de esta guía salen de una corrida verificada del notebook. Los datos de 2025 se generan dentro del notebook con semilla fija, así que tus cifras son exactamente estas.

1. El caso en una imagen



Lo que había adentro

LO QUE HAY PLANTADO EN EL ARCHIVO DE 2025

EL CRECIMIENTO NO ES PAREJO
Antofagasta +9,5 % y Metropolitana +1,2 %, con el sistema en +2,0 %
Se ve agrupando por región. El total del sistema lo esconde.

EL AÑO FUE SECO
La hidro cae 31,9 % y el gas sube 12,1 %. Entra un parque solar nuevo en julio
Se ve agrupando por tecnología los dos años.

UNA CENTRAL CONCENTRA FALLAS
64 eventos contra 22 del promedio, con 2.266 horas fuera de servicio
Se ve con un value_counts sobre la bitácora.

Los tres se encuentran con operaciones del Módulo 2. Lo difícil no es calcularlos, es acordarse de mirar por región en vez del total, y de corregir por el número de días entre un año bisiesto y uno que no lo es. Esa corrección la olvida casi todo el mundo y la encuentra siempre alguien después.

2. Parte 1, abrir el archivo nuevo

Qué había que lograr

Que el archivo de 2025 quedara usable y que quedara anotado qué defectos traía. Son cuatro, el separador punto y coma, la coma decimal, la fecha en formato chileno y catorce formas de escribir siete regiones.

El código, paso a paso

1.1 El archivo tal como llega

```
# 1.1 Mira el archivo tal como llega, sin arreglar nada.
import pandas as pd

crudo = pd.read_csv("demanda_2025.csv", sep=";")

print(crudo.shape)
crudo.head()
```

```
(61320, 4)
   fecha hora  region  mwh
0  01/01/2025  0  Antofagasta  58,27
1  01/01/2025  1  Antofagasta  53,07
2  01/01/2025  2  Antofagasta  52,90
3  01/01/2025  3  Antofagasta  52,13
4  01/01/2025  4  Antofagasta  53,36
```

Sale, y eso es lo peligroso. Si uno no mira los tipos, el error aparece mucho después.

1.2 El diagnóstico

```
# 1.2 El diagnóstico. Tipos, valores distintos y nulos.
print(crudo.dtypes.to_string())
print("\nregiones distintas", crudo["region"].nunique())
print("filas esperadas", 365 * 24 * 7, "contra", len(crudo))
```

```
fecha      object
hora       int64
region     object
mwh        object
```

```
regiones distintas 14
filas esperadas 61320 contra 61320
```

Tres columnas en object, catorce regiones donde debería haber siete, y el número de filas que sí calza. Las 61.320 son 365 por 24 por 7, o sea el año completo sin ser bisiesto.

1.3 Abierto bien

```
# 1.3 Ábrelo bien, arreglando en la lectura lo que se puede arreglar ahí.
d25 = pd.read_csv("demanda_2025.csv", sep=";", decimal=".",
                  parse_dates=["fecha"], dayfirst=True)

print(d25.dtypes.to_string())
```

```
fecha      datetime64[ns]
hora              int64
region      object
mwh           float64
```

Los tres arreglos en la lectura, como en el Módulo 3. Se puede resolver convirtiendo después con `astype`, y funciona igual. La diferencia aparece cuando el proceso se repite el mes siguiente, porque arreglar en la lectura no se olvida.

1.4 La región

```
# 1.4 Y normaliza la región, que no se puede arreglar en la lectura.
CANONICAS = {"antofagasta": "Antofagasta", "atacama": "Atacama", "coquimbo": "Coquimbo",
             "valparaiso": "Valparaiso", "metropolitana": "Metropolitana",
             "biobio": "Biobio", "los lagos": "Los Lagos"}
d25["region"] = d25["region"].str.strip().str.lower().map(CANONICAS)

print("regiones distintas", d25["region"].nunique(), " nulos", int(d25["region"].isna().sum()))
```

```
regiones distintas 7  nulos 0
```

El `map` con el diccionario deja en nulo lo que no calce, así que contar los nulos es la comprobación. Si da cero, las catorce variantes se redujeron bien a siete.

1.5 Todo lo demás

```
# 1.5 Carga lo demás y deja todo listo para trabajar.
g25 = pd.read_csv("generacion_2025.csv", parse_dates=["fecha"])
c25 = pd.read_csv("centrales_2025.csv")
m25 = pd.read_csv("mantenimiento_2025.csv", parse_dates=["fecha"])
g25 = g25.merge(c25, on="central")

d24 = pd.read_csv("demanda.csv", parse_dates=["fecha"])
g24 = pd.read_csv("generacion.csv", parse_dates=["fecha"]).merge(pd.read_csv("centrales.csv"),
                                                                on="central")

print("2025", d25.shape, g25.shape, m25.shape)
print("2024", d24.shape, g24.shape)
```

```
2025 (61320, 4) (183960, 8) (512, 4)
2024 (61488, 4) (175680, 8)
```

Los otros tres archivos llegan limpios. Conviene comprobarlo igual, y no buscar defectos donde no los hay.

Lo que había que dejar anotado

Cuatro líneas en una celda de texto. El archivo llegó con separador punto y coma, coma decimal, fecha en formato de día primero y catorce variantes de escritura de las regiones. Los tres primeros se arreglaron en la lectura y el cuarto con un diccionario, sin perder filas.

Es lo primero que pregunta quien revise el informe.

3. Parte 2, comparar 2025 con 2024

El detalle que separa las soluciones

2024 fue bisiesto y 2025 no. Comparar los totales sin corregir por el número de días sobrestima 2024. La diferencia es de unas tres décimas de punto, que es chica y es real, y es exactamente el tipo de cosa que alguien encuentra después.

El código, paso a paso

2.1 El total, corregido

```
# 2.1 El total del sistema, corrigiendo por el número de días.
tot24 = d24["mwh"].sum() / 1000
tot25 = d25["mwh"].sum() / 1000
dia24 = tot24 / 366
dia25 = tot25 / 365

print(f"2024 {tot24:9.0f} GWh en 366 días, {dia24:6.1f} GWh por día")
print(f"2025 {tot25:9.0f} GWh en 365 días, {dia25:6.1f} GWh por día")
print(f"variación por día {100 * (dia25 / dia24 - 1):+.2f} por ciento")
```

```
2024      13899 GWh en 366 días,   38.0 GWh por día
2025      14134 GWh en 365 días,   38.7 GWh por día
variación por día +1.97 por ciento
```

Dos coma cero por ciento por día. Sin corregir por días daría uno coma siete.

2.2 Por región

```
# 2.2 Y ahora por región, que es lo que de verdad pidieron.
por_region = pd.DataFrame({
    "gwh_2024": d24.groupby("region")["mwh"].sum() / 1000 / 366,
    "gwh_2025": d25.groupby("region")["mwh"].sum() / 1000 / 365,
})
por_region["var_pct"] = (100 * (por_region["gwh_2025"] / por_region["gwh_2024"] - 1)).round(1)

print(por_region.round(2).sort_values("var_pct", ascending=False).to_string())
```

region	gwh_2024	gwh_2025	var_pct
Antofagasta	1.84	2.01	9.5
Atacama	0.84	0.87	3.1
Coquimbo	2.23	2.29	2.5
Biobio	4.46	4.56	2.2
Valparaiso	4.99	5.08	1.8
Los Lagos	2.36	2.40	1.7
Metropolitana	21.26	21.52	1.2

Acá está la respuesta a la primera pregunta del encargo. Antofagasta sube 9,5 por ciento y la Metropolitana 1,2. El total del sistema no lo mostraba, y la pregunta era justamente si el crecimiento fue parejo.

2.3 Por tecnología

```
# 2.3 La generación por tecnología, mismo tratamiento.
por_tec = pd.DataFrame({
    "gwh_2024": g24.groupby("tecnologia")["mwh"].sum() / 1000 / 366,
    "gwh_2025": g25.groupby("tecnologia")["mwh"].sum() / 1000 / 365,
})
por_tec["var_pct"] = (100 * (por_tec["gwh_2025"] / por_tec["gwh_2024"] - 1)).round(1)

print(por_tec.round(2).sort_values("var_pct").to_string())
```

	gwh_2024	gwh_2025	var_pct
tecnologia			
hidro	16.68	11.35	-31.9
eolica	4.28	4.27	-0.1
carbon	12.75	12.76	0.0
diesel	0.11	0.11	0.3
gas	13.92	15.60	12.1
solar	1.84	2.10	14.2

La hidro cae casi 32 por ciento y el gas sube 12. La solar sube 14, que es más de lo que explica el crecimiento de la demanda.

2.4 La central nueva

```
# 2.4 Hay una central que no estaba el año pasado.
nuevas = set(g25["central"]) - set(g24["central"])
print("centrales nuevas en 2025:", nuevas)

rio = g25[g25["central"] == "Parque Solar Rio Seco"]
print("primer día con generación:", rio.loc[rio["mwh"] > 0, "fecha"].min().date())
print("aporte del año:", round(rio["mwh"].sum() / 1000, 1), "GWh")
```

```
centrales nuevas en 2025: {'Parque Solar Rio Seco'}
primer día con generación: 2025-07-01
aporte del año: 89.5 GWh
```

Y ahí está la explicación de la solar. Hay una central que no estaba en 2024, entró el primero de julio y aportó 89,5 GWh en medio año. Si uno no compara las listas de centrales, esa subida queda sin explicación.

La pregunta que cierra la parte

La hidro cayó y el gas subió. ¿Son dos hechos o uno solo?

Lo razonable es que sea uno. En un sistema que tiene que abastecer la demanda hora a hora, lo que no genera una tecnología lo tiene que generar otra, y el gas suele ser el que absorbe. Pero eso es una interpretación y no un dato.

El dato que haría falta para confirmarlo es el hidrológico del año, cotas de embalses o caudales. Pedirlo es parte del informe.

4. Parte 3, qué se salió de la norma

La trampa de esta parte

Viniendo de los módulos 4 y 5, la tentación es aplicar reglas de asociación o agrupamiento sobre los 512 eventos. Con veintiuna centrales y seis tipos, eso es usar una grúa para levantar una caja.

La herramienta más simple que responde la pregunta es la correcta, y acá es contar.

El código, paso a paso

3.1 Contar

```
# 3.1 Lo más simple primero. Cuántos eventos tuvo cada central.
print(m25["central"].value_counts().head(6).to_string())
```

```
central
Termoelectrica Puerto Sur      64
Diesel Respaldo Cordillera    30
Central Aguas Claras          22
Central Vega Azul             22
Parque Solar Quebrada Honda   22
Termoelectrica Bahia Norte    22
```

Sesenta y cuatro contra veintidós. Una línea.

3.2 De qué tipo son

```
# 3.2 Esa central concentra eventos. De qué tipo son.
foco = m25[m25["central"] == "Termoelectrica Puerto Sur"]

print(foco["tipo_evento"].value_counts().to_string())
print("\nhoras fuera de servicio en el año:", int(foco["duracion_horas"].sum()))
```

```
tipo_evento
falla_electrica      20
correctivo           19
falla_mecanica       14
preventivo           5
inspeccion           4
evento_climatico     2

horas fuera de servicio en el año: 2266
```

Veinte fallas eléctricas y diecinueve correctivos. Es el patrón del Módulo 4, concentrado en una sola central.

3.3 Contra el resto

```
# 3.3 Compárala con el resto para saber si el número es raro de verdad.
resto = m25[m25["central"] != "Termoelectrica Puerto Sur"]

print("Puerto Sur      ", len(foco), "eventos,", int(foco["duracion_horas"].sum()), "horas")
print("promedio del resto",
      round(resto.groupby("central").size().mean(), 1), "eventos,",
      round(resto.groupby("central")["duracion_horas"].sum().mean()), "horas")
```

```
Puerto Sur      64 eventos, 2266 horas
promedio del resto 22.4 eventos, 520 horas
```

Esta celda es la que convierte un número en un hallazgo. Sin comparar contra el resto, sesenta y cuatro no significa nada.

3.4 Si se le notó

```
# 3.4 Y la pregunta que importa. ¿Se le notó en la generación?
ps25 = g25[g25["central"] == "Termoelectrica Puerto Sur"]["mwh"].sum() / 1000
ps24 = g24[g24["central"] == "Termoelectrica Puerto Sur"]["mwh"].sum() / 1000

print(f"Puerto Sur 2024 {ps24:7.1f} GWh 2025 {ps25:7.1f} GWh"
      f" {100 * (ps25 / 366) / (ps24 / 365) - 100:+.1f} por ciento por día")
```

```
Puerto Sur 2024 1688.5 GWh 2025 1886.7 GWh +11.4 por ciento por día
```

La pregunta que de verdad importa para el informe. Si una central estuvo 2.266 horas fuera de servicio, hay que mirar si se le notó en la generación.

Las dos listas

QUÉ SE PUEDE AFIRMAR Y QUÉ NO

Se puede afirmar que una central concentró 64 eventos de mantenimiento contra 22 del promedio de las otras veinte, que 20 de esos eventos fueron fallas eléctricas y 19 correctivos, y que acumuló 2.266 horas de eventos en el año.

No se puede afirmar que la central esté fallando por antigüedad, ni por mala operación, ni por falta de mantenimiento, ni que vaya a seguir fallando. Nada de eso está en los datos.

Un hallazgo es un lugar donde mirar. La causa la investiga quien corresponde, y el trabajo de uno es que sepan dónde mirar.

5. Parte 4, las tres figuras

Una por pregunta

El informe es de una página y lleva tres figuras, una por pregunta del encargo. Cada una tiene que entenderse sola.


El código, paso a paso

4.1 La variación por región

```
# 4.1 Figura 1. El crecimiento de la demanda por región.
import matplotlib.pyplot as plt

orden = por_region.sort_values("var_pct")

fig, ax = plt.subplots(figsize=(8, 3.5))
colores = ["#E45756" if v > 5 else "#4C78A8" for v in orden["var_pct"]]
ax.barh(orden.index, orden["var_pct"], color=colores)
ax.set_title("Variación de la demanda diaria promedio por región, 2025 contra 2024")
ax.set_xlabel("variación porcentual")
ax.bar_label(ax.containers[0], fmt="%+.1f%", padding=3, fontsize=8)
ax.set_xlim(0, orden["var_pct"].max() * 1.25)
plt.show()
```



Barras horizontales, ordenadas, con el valor al lado y el color destacando el caso que se sale del resto. El `set_xlim` con un veinticinco por ciento extra es para que la etiqueta de la barra más larga no se corte.

4.2 La generación por tecnología

4.2 Figura 2. La generación por tecnología, los dos años.

```
import numpy as np
```

```
t = por_tec.sort_values("gwh_2025", ascending=False)
```

```
x = np.arange(len(t))
```

```
fig, ax = plt.subplots(figsize=(8.5, 3.5))
```

```
ax.bar(x - 0.2, t["gwh_2024"], 0.4, label="2024", color="#B8B8B8")
```

```
ax.bar(x + 0.2, t["gwh_2025"], 0.4, label="2025", color="#4C78A8")
```

```
ax.set_xticks(x)
```


```
ax.set_xticklabels(t.index)
```

```
ax.set_title("Generación diaria promedio por tecnología, 2024 contra 2025")
```

```
ax.set_ylabel("GWh por día")
```

```
ax.legend()
```

```
plt.show()
```




Barras agrupadas, no apiladas, porque lo que se compara es cada tecnología consigo misma entre los dos años. Apiladas solo permitirían comparar bien la de abajo.

4.3 La central, mes a mes

```
# 4.3 Figura 3. La central con problemas, mes a mes.
foco_mes = foco.groupby(foco["fecha"].dt.month).size()
resto_mes = resto.groupby(resto["fecha"].dt.month).size() / resto["central"].nunique()

fig, ax = plt.subplots(figsize=(8.5, 3.5))
ax.bar(foco_mes.index - 0.2, foco_mes.values, 0.4,
      label="Termoelectrica Puerto Sur", color="#E45756")
ax.bar(resto_mes.index + 0.2, resto_mes.values, 0.4,
      label="promedio de las otras veinte", color="#B8B8B8")
ax.set_title("Eventos de mantenimiento por mes, 2025")
ax.set_xlabel("mes")
ax.set_ylabel("eventos")
ax.set_xticks(range(1, 13))
ax.legend(fontsize=8)
plt.show()
```



La decisión buena de esta figura es comparar contra el promedio de las otras veinte y no contra el total. Sin esa normalización, la barra gris sería veinte veces más alta y no se compararía nada.

La vuelta de revisión

La lista del Módulo 6, aplicada a las tres.

Título con el periodo	Las tres dicen 2025, o 2024 contra 2025
Ejes con su unidad	Variación porcentual, GWh por día, eventos
Orden si son categorías	La primera está ordenada por variación
Escala desde cero en barras	Las tres, y la primera lo declara con el <code>set_xlim</code>
Paleta que distinga cualquiera	Rojo contra azul y gris, que se distinguen sin color

6. Parte 5, el cierre

Las tres afirmaciones

5.1 Armadas con los números calculados

```
# 5.1 Las tres afirmaciones del informe, armadas con los números calculados.
# Escribirlas a mano invita a que se desactualicen. Así no puede pasar.
sistema = 100 * (dia25 / dia24 - 1)
arriba = por_region["var_pct"].idxmax()
abajo = por_region["var_pct"].idxmin()

print(f"1. La demanda del sistema creció {sistema:.1f} por ciento por día, y el crecimiento")
print(f"    no fue parejo. {arriba} subió {por_region.loc[arriba, 'var_pct']:.1f} por ciento"
      f" y {abajo} {por_region.loc[abajo, 'var_pct']:.1f}.")
print()
print(f"2. La hidro cayó {abs(por_tec.loc['hidro', 'var_pct']):.1f} por ciento y el gas subió"
      f" {por_tec.loc['gas', 'var_pct']:.1f}. Entró además un parque")
print(f"    solar nuevo en julio, que aportó {rio['mwh'].sum() / 1000:.1f} GWh en medio año.")
print()
print(f"3. Una central concentró {len(foco)} eventos de mantenimiento contra"
      f" {resto.groupby('central').size().mean():.0f} del promedio,")
print(f"    con {int(foco['duracion_horas'].sum()):,} horas fuera de servicio en el año."
      .replace(",","."))
```

1. La demanda del sistema creció 2.0 por ciento por día, y el crecimiento no fue parejo. Antofagasta subió 9.5 por ciento y Metropolitana 1.2.
2. La hidro cayó 31.9 por ciento y el gas subió 12.1. Entró además un parque solar nuevo en julio, que aportó 89.5 GWh en medio año.
3. Una central concentró 64 eventos de mantenimiento contra 22 del promedio, con 2.266 horas fuera de servicio en el año.

Fíjate en que ninguna cifra está escrita a mano, todas salen de las variables. Una cifra escrita a mano en un informe se desactualiza sola, y nadie se entera hasta que alguien la comprueba.

Lo que va y lo que no va

VA EN EL INFORME	NO VA
Los tres hechos, con su cifra	Por qué cayó la hidro
El periodo y la corrección por días	Que la central falla por antigüedad
Las tres figuras	Cualquier causa no investigada
Qué defectos traía el archivo	Una proyección para 2026
Qué dato haría falta pedir	Lo que no se puede rehacer

La columna de la derecha no es una lista de omisiones, es parte del informe. Decir que el patrón de la hidro es compatible con un año seco y que hace falta el dato hidrológico para confirmarlo es más útil que afirmarlo, porque además le dice a la jefatura qué pedir. Un hallazgo es un lugar donde mirar, no una causa demostrada.

Los dos defectos que se castigan parejo son el contrario uno del otro. Afirmar una causa que no se investigó deja el informe indefendible en la primera pregunta. Callar lo que quedó sin resolver deja a quien decide sin saber qué falta. Lo que sostiene el informe es decir las dos cosas en la misma frase.

El informe de una página, si lo tuvieras que escribir

Demanda. Creció 2,0 por ciento por día respecto de 2024, corrigiendo por el número de días del año. El crecimiento no fue parejo. Antofagasta subió 9,5 por ciento y la Metropolitana 1,2.

Generación. La hidro cayó 31,9 por ciento y el gas subió 12,1. El patrón es compatible con un año seco y se requiere el dato hidrológico para confirmarlo. Entró además un parque solar nuevo en julio, que aportó 89,5 GWh en medio año.

Mantenimiento. Una central concentró 64 eventos contra 22 del promedio, con 2.266 horas en el año, principalmente fallas eléctricas y correctivos. Se recomienda revisar el caso. No hay antecedentes en estos datos para establecer la causa.

Nota metodológica. El archivo de demanda de 2025 llegó con separador punto y coma, coma decimal, fecha en formato de día primero y catorce variantes de escritura de las regiones. Los cuatro defectos se corrigieron sin perder filas.

Lo que se lleva del curso

Los seis módulos, en una plana

Módulo 1	Los datos llegan de muchas partes y en muchos formatos, y unir dos tablas es una decisión, no un trámite. El how del join cambia el total.
Módulo 2	Filtrar, agrupar y pivotar responde casi todas las preguntas de un informe. El total del sistema casi nunca es la pregunta.
Módulo 3	Un archivo nuevo se diagnostica antes de calcularle nada. Cada decisión de limpieza cambia el resultado, así que se deja marcada.
Módulo 4	Un patrón se encuentra con una técnica y se mide con otra. Un porcentaje sacado de reglas, sin su ventana, no se puede usar.
Módulo 5	Sin respuesta correcta, el trabajo está antes, en preparar los datos, y después, en justificar el resultado. Un grupo que no se puede nombrar no sirve.
Módulo 6	El gráfico es la parte del análisis que viaja sola. Y se revisa antes de mandarlo, con una lista de cinco cosas.

Y el método, que es lo que de verdad se lleva

- Mirar antes de calcular.
- Decidir a conciencia, sabiendo que había otras opciones.
- Medir lo que uno decidió, cuando se puede.
- Dejarlo escrito, para que otro lo pueda rehacer y discutir.

Ninguno de los cuatro es una función de pandas.